
DeepDive™

organizacyjne

DeepDive™

Czym jest AI?



DeepDive™

Czym jest AI?

ARTIFICIAL INTELLIGENCE (AI)
W JĘZYKU POLSKIM: SZTUCZNA INTELIGENCJA (SI)

to programy komputerowe oparte na uczeniu maszynowym potrafiące **przyjmować dane od użytkowników i uczyć się na nich**. Nauczone programy potrafią transformować lub generować od nowa dane na podstawie zapamiętanych parametrów zależnie od potrzeb wykorzystania.



Supervised Learning



Machine Learning

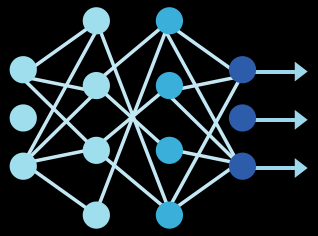


Unsupervised Learning

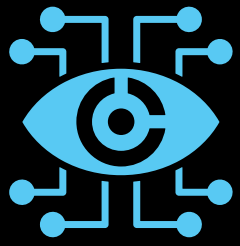


Reinforcement Learning

Typy AI



Deep Learning



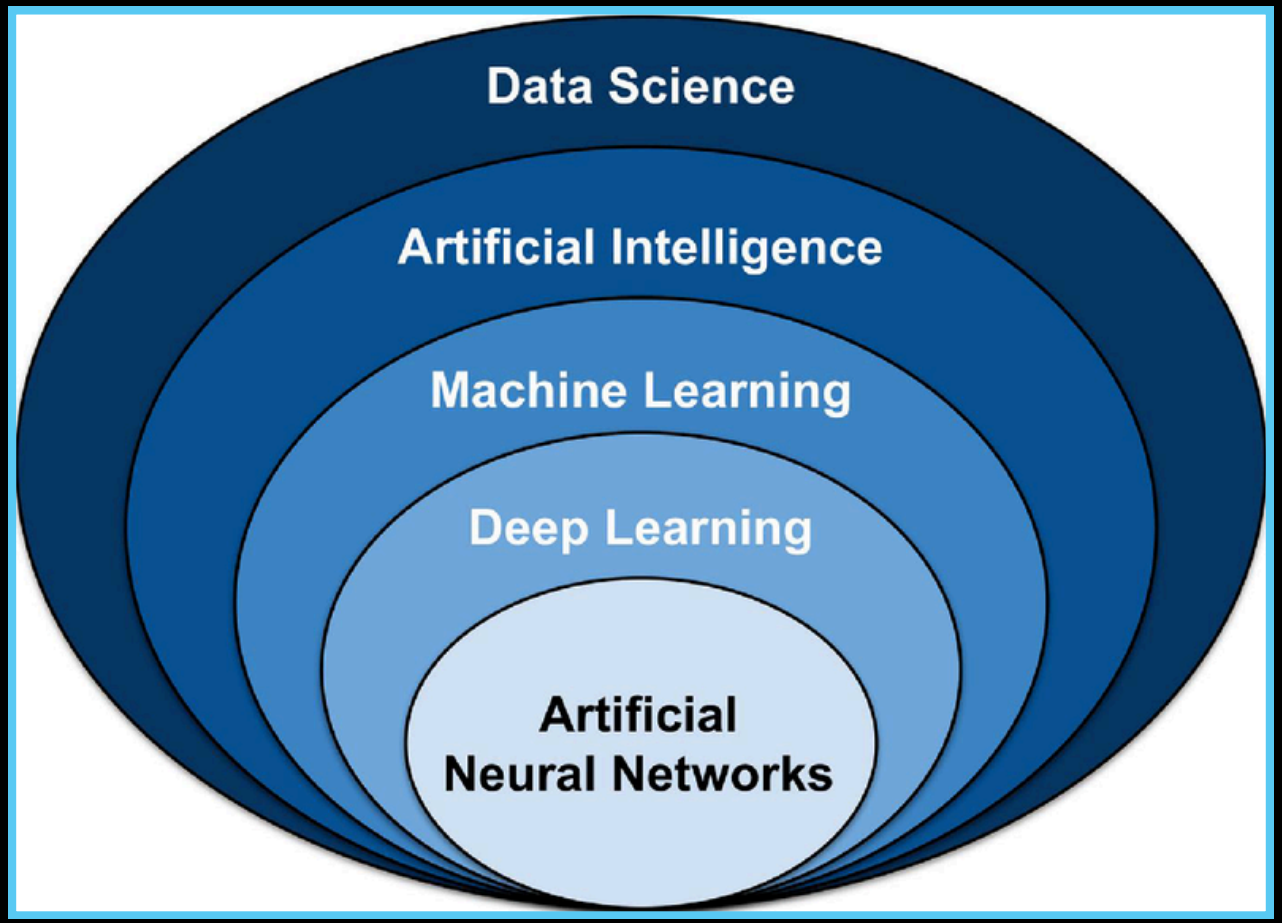
Computer Vision



Natural Language Processing

DeepDive™

Typy AI



https://viso.ai/deep-learning/ml-ai-models/

DeepDive™

Klasyfikacja



DeepDive™

Klasyfikacja



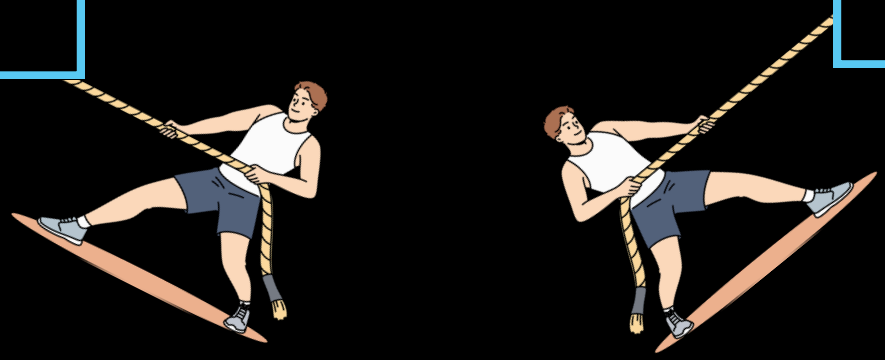
https://viso.ai/deep-learning/ml-ai-models/

DeepDive™

Regresja

zmienna zależna (docelowa)

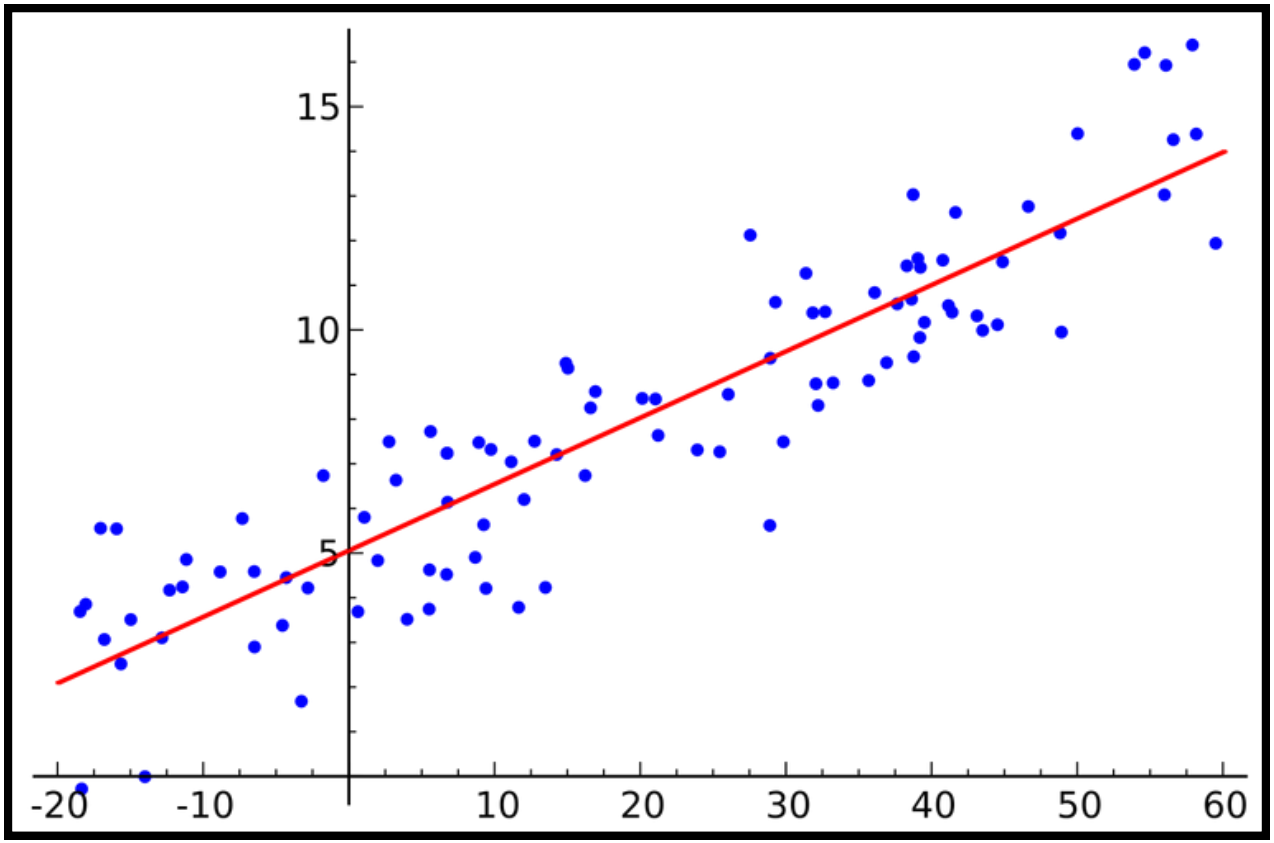
zmienne niezależne (predykcyjne)



funkcja

DeepDive™

Regresja



DeepDive™

Gdzie znaleźć dodatkowe materiały o AI?

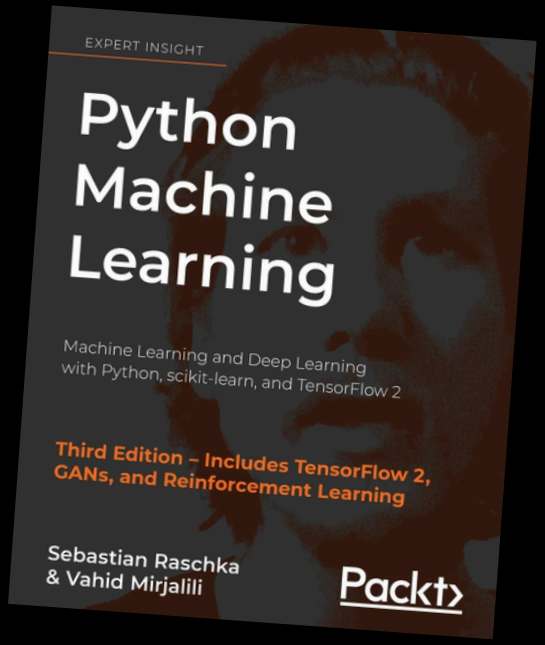
kaggle

Sebastian Raschka

GeeksforGeeks

Literatura





DeepDive™

Preprocessing danych

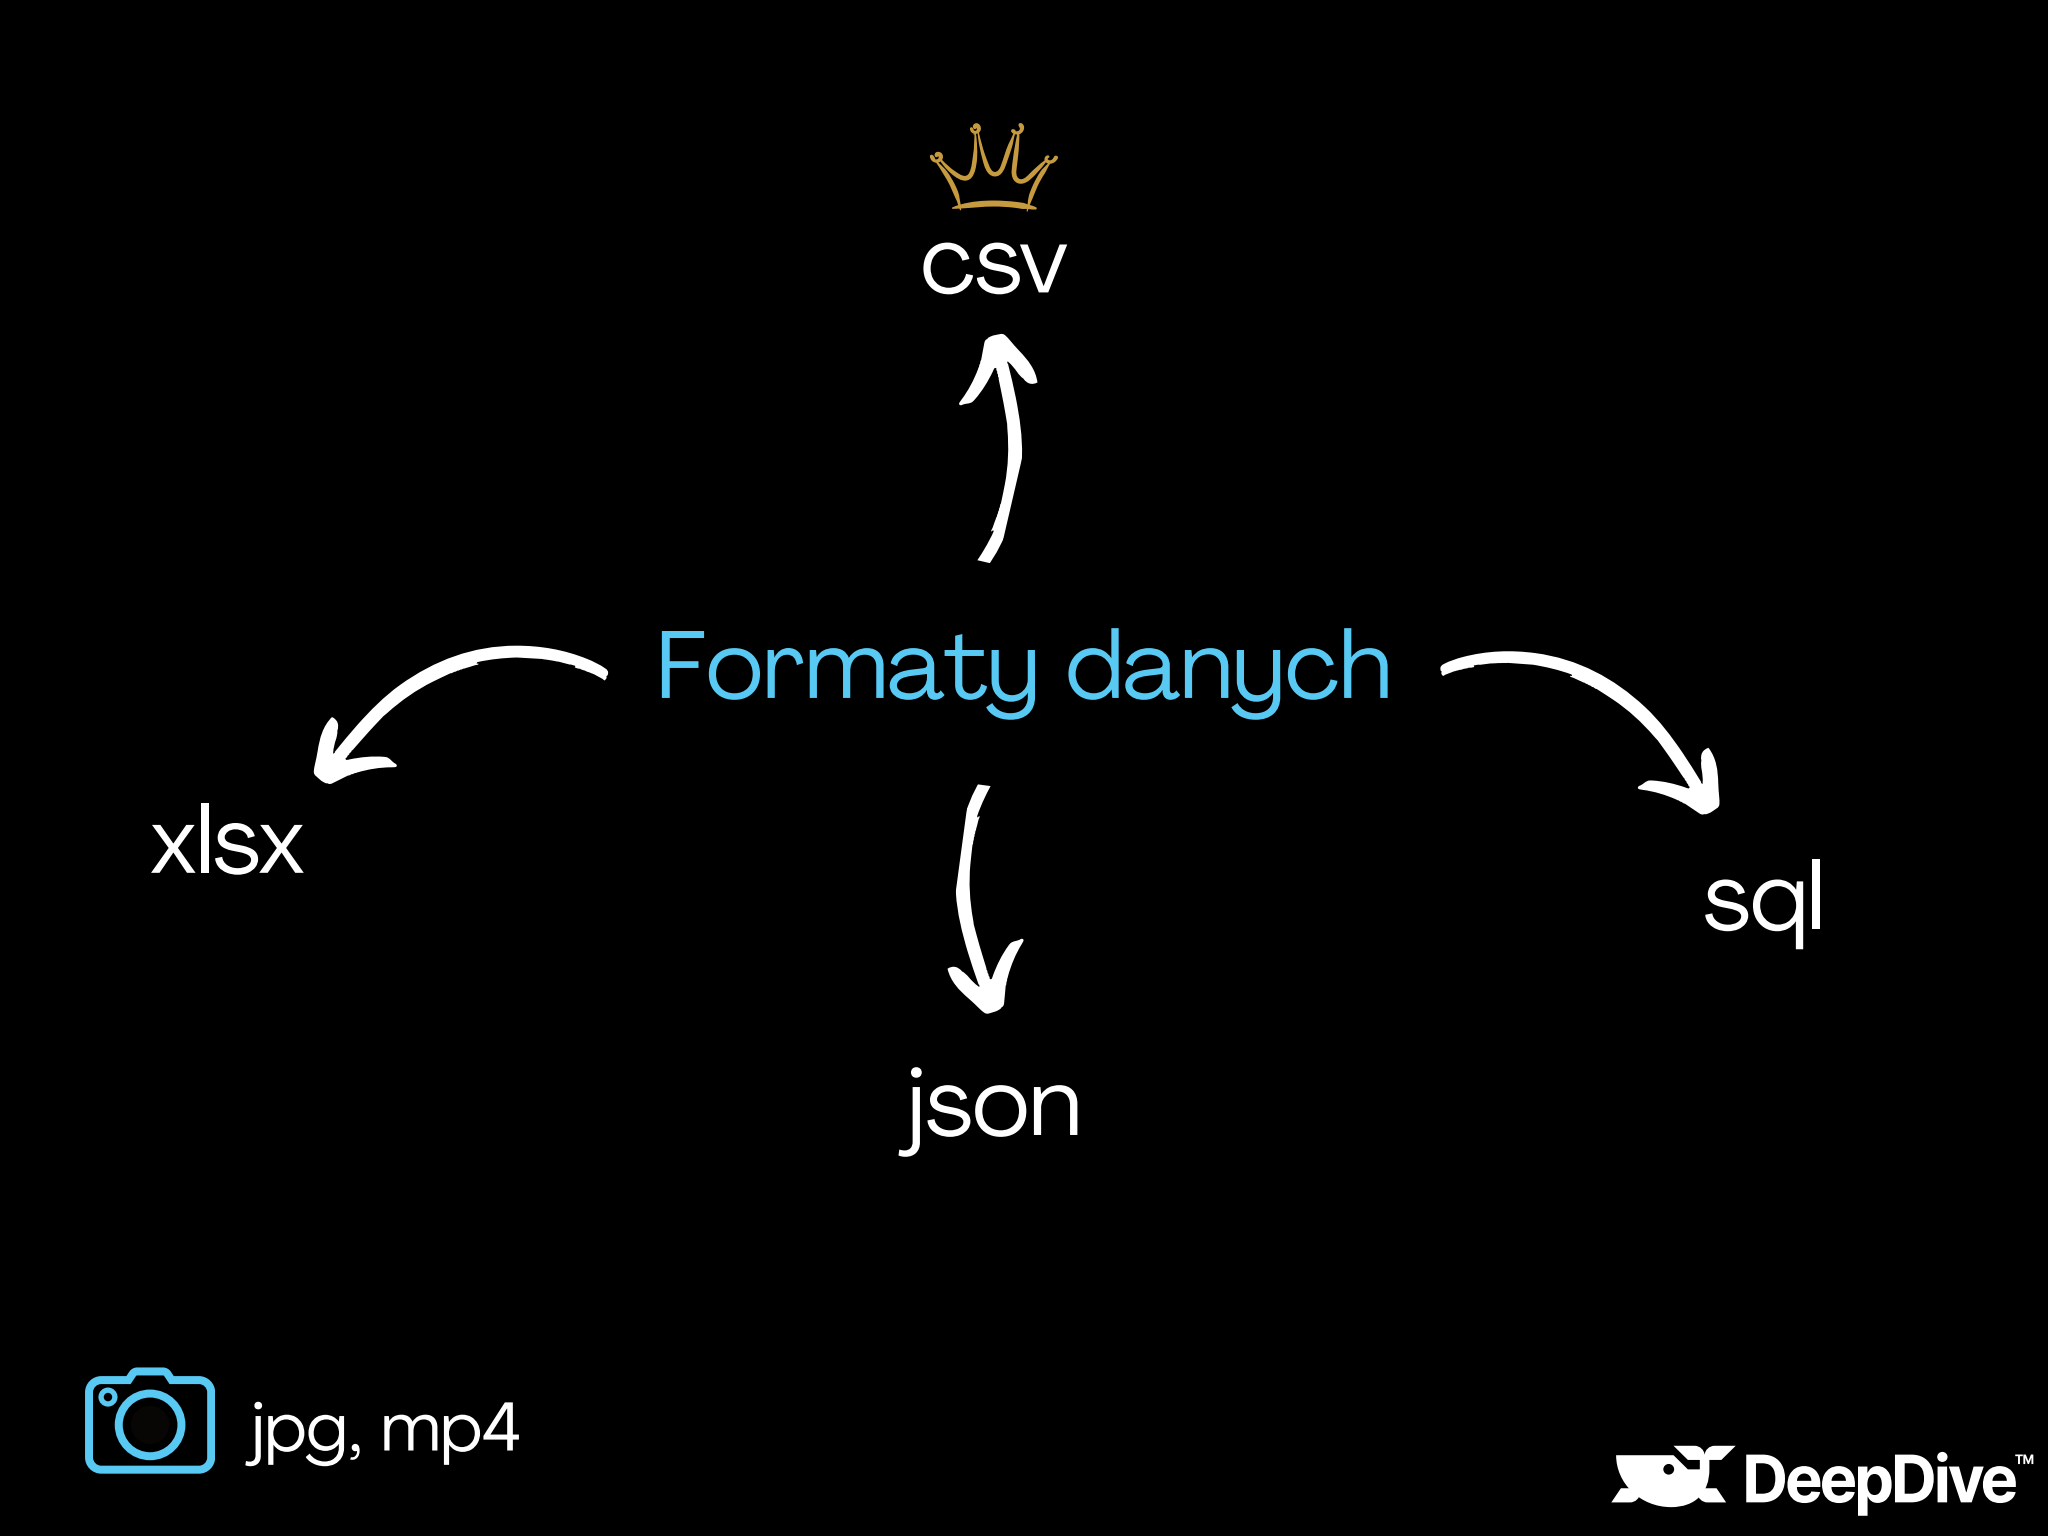


DeepDive™

Jakie mogą być formaty danych?



DeepDive™


csv
Formaty danych
xlsx
sql
json
jpg, mp4
DeepDive™


HOW THE CLIENT
DESCRIBED THEIR DATA
Excel
XML
TXT
PDF
THEIR DATA

DeepDive™

Typy danych

Dane numeryczne

wartości wyrażone liczbami, na których można wykonywać działania matematyczne.

Ciągłe – mogą przyjmować dowolną wartość w zakresie
np. temperatura: 36,7°C, masa: 72,4 kg

Dyskretne – przyjmują określone, najczęściej całkowite wartości
np. liczba wizyt: 4, liczba produktów: 12

Dane kategoryczne

opisują przynależność do określonej grupy lub klasy.

Nominalne – bez naturalnej kolejności
np. kolor, kraj, typ urządzenia

Porządkowe – kategorie mają określoną kolejność
np. niski → średni → wysoki

Binarne – tylko 2 możliwe wartości
np. tak/nie, 0/1

DeepDive™

Gdzie znaleźć dane?



DeepDive™

Gdzie znaleźć dane?

kaggle







Przygotowanie Danych



errors

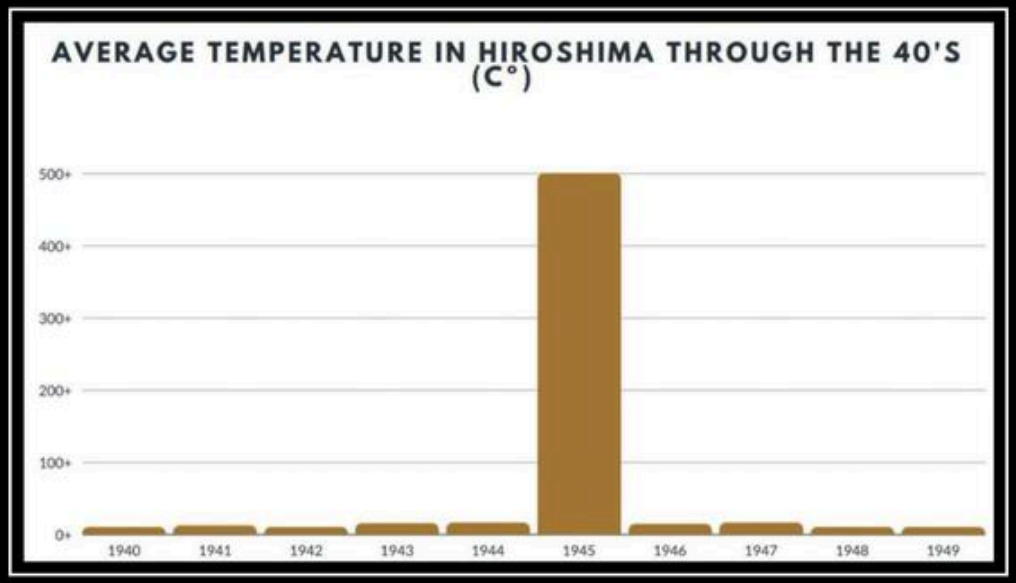
inconsistent data

NaN

outliers

DeepDive™

Przygotowanie Danych



GLOBAL WARMING

https://knowyourmeme.com/photos/2104681-okbuddyretard

DeepDive™

Etapy czyszczenia danych

- ✓ ogarnięcie NaN-ów
- ✓ poprawa niespójności (np. Male/M/man)
- ✓ usunięcie duplikatów
- ✓ usunięcie zbędnych kolumn
- ✓ poprawa typów danych (float, datetime)
- ✓ ogarnięcie outlierów
- ✓ walidacja logiczna
- ✓ normalizacja/standaryzacja



DeepDive™

Obsługa brakujących danych

Brakujące dane, czyli wartości NaN, None lub puste pola w zbiorze danych.

1. Identyfikacja braków: sprawdzenie liczby/% braków w kolumnach za pomocą np. isna(), isnull()

2. Usuwanie braków za pomocą dropna(), czyli usunięcie wierszy lub kolumn z brakami. Sensowne, gdy braków jest mało i ich usunięcie nie zniekształca danych

3. Uzupełnianie braków, czyli imputacja
dane numeryczne → średnia, mediana
dane kategoryczne → moda, "Unknown"
przykład: fillna()

4. Czasem informacja o samym braku
można dodać kolumnę typu was_missing = 0/1
sam fakt braku może być czasem istotną cechą dla modelu

DeepDive™

Kodowanie danych kategorycznych

Modele ML zazwyczaj pracują na liczbach,
dlatego kategorie tekstowe trzeba przekształcić do postaci numerycznej.

Label Encoding

każda kategoria → liczba
kot → 0, pies → 1, koń → 2
dobre głównie dla danych porządkowych
przy danych nominalnych może sztucznie sugerować kolejność

One-Hot Encoding

każda kategoria → osobna kolumna 0/1
kolor = czerwony → [1, 0, 0]
dobre dla danych nominalnych
wada: dużo kategorii to dużo nowych kolumn

Ordinal Encoding

przypisujemy liczby zgodnie z rzeczywistą kolejnością
niski → 0, średni → 1, wysoki → 2

DeepDive™

Skalowanie

przekształcanie cech numerycznych tak,
aby miały porównywalny zakres wartości



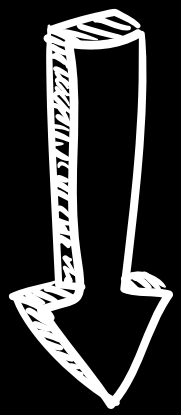
Po co skalować?

→ żeby cechy o dużych wartościach nie dominowały nad pozostałymi
→ żeby poprawić działanie algorytmów opartych na odległości i gradientach
→ dla szybszego/stabilniejszego uczenia modelu

DeepDive™

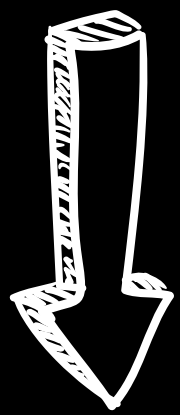
Skalowanie danych

STANDARYZACJA



średnia = 0
odchylenie = 1

NORMALIZACJA



wartości z zakresu [0,1]

DeepDive™

Standaryzacja danych

Aby sprowadzić dane do rozkładu normalnego:

- Wczytujemy dane,
- Z całego przedziału danych odczytujemy średnią i odchylenie standardowe,
- Wykonujemy standaryzację: S = (dane - średnia) / odchylenie.

Aby przywrócić dane do stanu przed standaryzacją:

- Wczytujemy parametry użyte w standaryzacji
- dane = S * odchylenie + średnia

DeepDive™

Standaryzacja Danych

```python
import numpy as np
import numpy.typing as npt

# dane = []
# for _ in range(10):
#     dane.append(np.random.randint(-4,10))

# Generujemy losowe liczby całe z zakresu [-4; 10)
dane: list[int] = [np.random.randint(-4,  high: 10) for _ in range(10)]  # ← Komprehensja list. Analog w komentarzu wyżej
dane_array: npt.NDArray = np.array(dane)  # Konwersja na np.NDArray


def standaryzacja(dane: npt.NDArray) → tuple[npt.NDArray, tuple[np.float64, np.float64]]:  1 usage
    srednia: np.float64 = dane.mean()
    odchylenie: np.float64 = dane.std()
    return (dane - srednia) / odchylenie, (srednia, odchylenie)


def przywrocenie_standaryzacji(standaryzowane: npt.NDArray, srednia: np.float64, odchylenie: np.float64) → npt.NDArray:
    return standaryzowane * odchylenie + srednia

print(f"Dane wejściowe: {dane_array}")
standaryzowane, parametry = standaryzacja(dane_array)
print(f"Dane standaryzowane: {standaryzowane}\nŚrednia: {parametry[0]}\nSTD: {parametry[1]}")
przywrocone_dane = przywrocenie_standaryzacji(standaryzowane, *parametry)
print(f"Przywrócone dane: {przywrocone_dane}")
```

Przykład standaryzacji, Jakub Susoł

DeepDive™

Standaryzacja

średnia 0 z odchyleniem 1

Normalizacja

wartości w przedziale [0, 1]

KIEDY?

różne jednostki lub zakresy żeby zachować porównywalny wpływ (normalizacja spłaszcza różnice)

outliery są isotne

metoda zakłada rozkład normalny lub używa odległości euklidesowej

np. HCA, PCA, regresja, metody oparte o macierze kowariancji

ważne rzeczywiste proporcje wartości (np. obrazy)

metody oparte na odległości Manhattan

np. sieci neuronowe (szybsza nauka), KNN, gradient boosting

DeepDive™

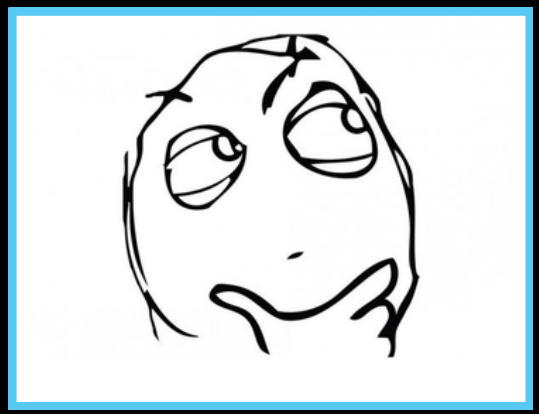
Amazon's AI Recruting Tool: seksizm wbudowany w dane



★★★☆☆

DeepDive™

Amazon's AI Recruting Tool: seksizm wbudowany w dane



Czy to wina modelu czy danych?

Czy można było to naprawić?

Czy rekrutacja przez AI może być w ogóle sprawiedliwa?

DeepDive™

JAKOŚĆ DANYCH
JEST KLUCZOWA DLA MODELU!



DeepDive™

EDA
(Exploratory Data Analysis)



CEL:
zrozumienie rozkładu,
zależności i problemów

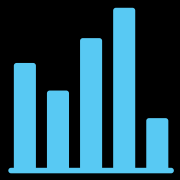


DeepDive™

EDA
(Exploratory Data Analysis)



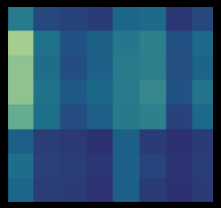
statystyki opisowe



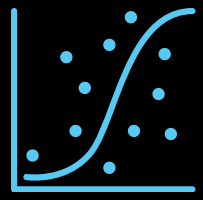
rozkłady, histogramy



rozkład klas



korelacje



wizulizacje outlierów
(boxplot, scatter plot)

DeepDive™

Statystyki opisowe

Służą do szybkiego poznania rozkładu i jakości danych przed budową modelu.

Miary położenia

średnia – przeciętna wartość
mediana – wartość środkowa
moda – najczęściej występująca wartość

Miary rozproszenia

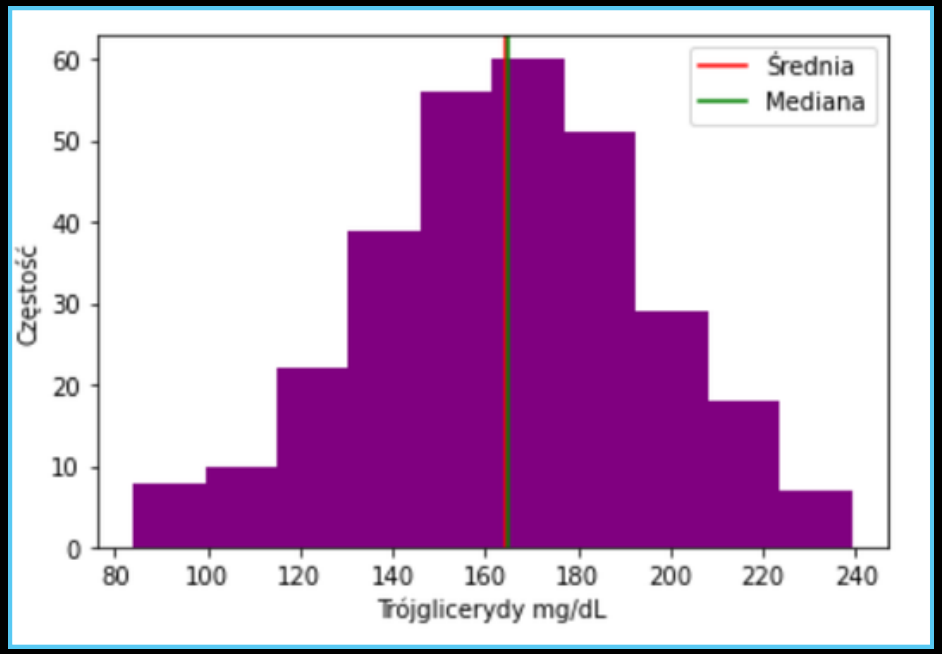
min/max – zakres wartości
range = max - min
wariancja – zróżnicowanie danych
odchylenie standardowe – typowe odchylenie od średniej
IQR = Q3 - Q1 – rozstęp międzykwartylowy
Kwantyle
Q1 – 25%
Q2 – 50% = mediana
Q3 – 75%

Dla danych kategorycznych

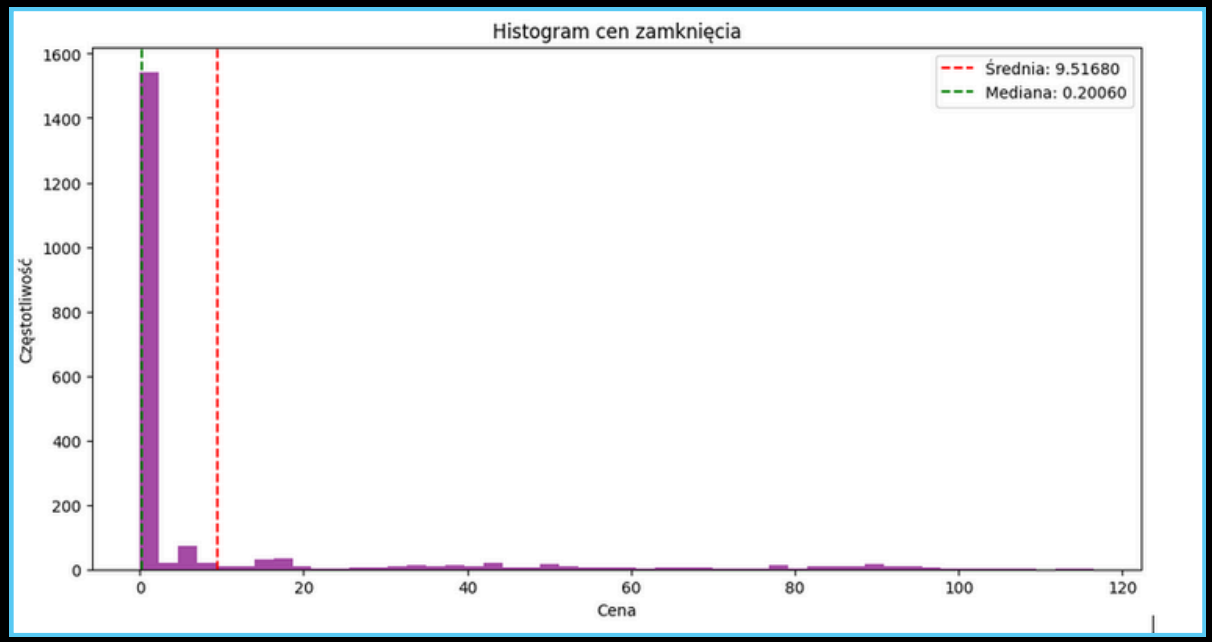
liczba unikalnych wartości
częstość występowania kategorii
najczęstsza kategoria

DeepDive™

Rozkład

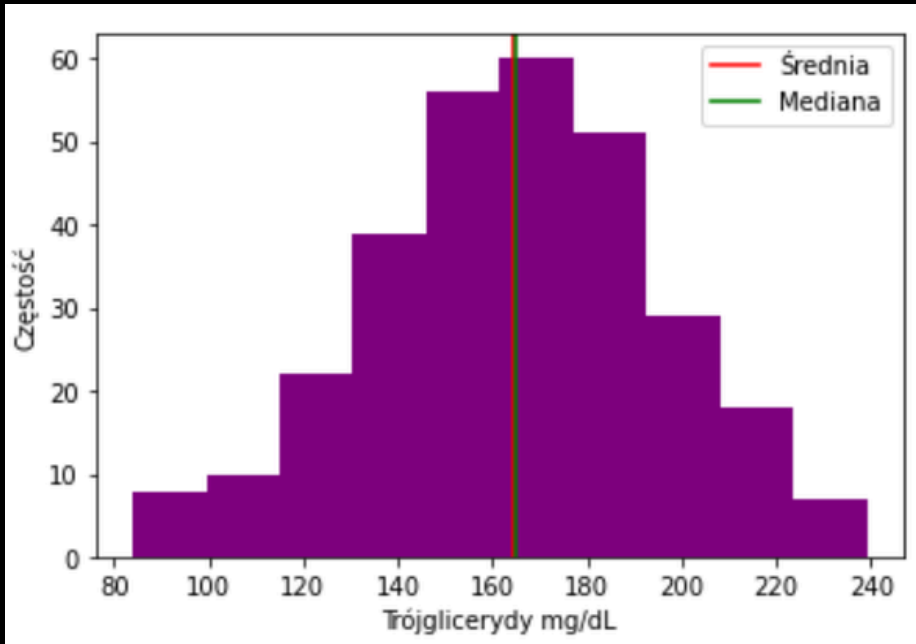


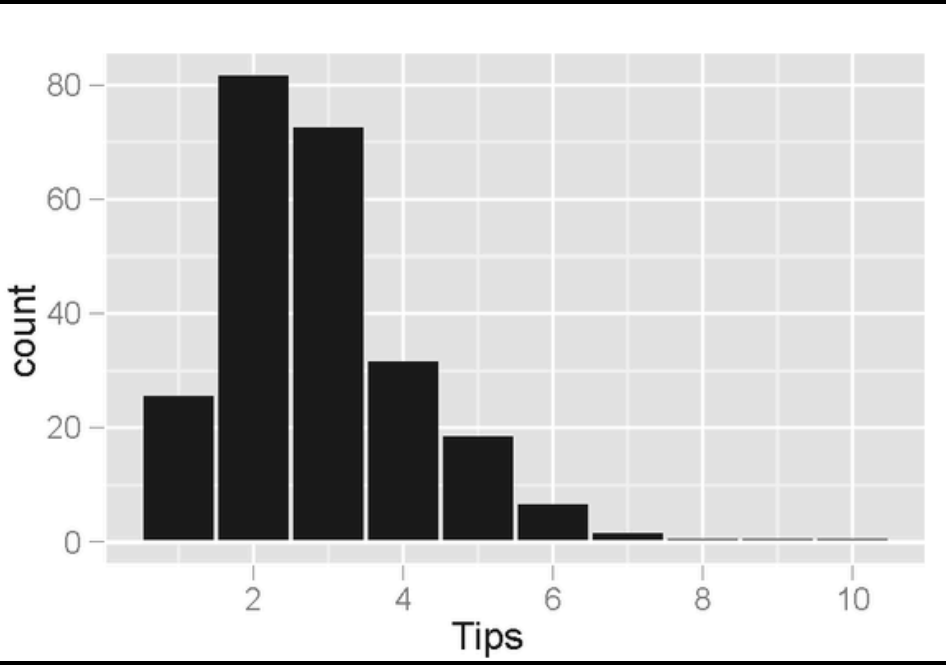
Czy jest normalny?



DeepDive™

Histogramy





W jaki sposób dane są rozłożone w danej serii, np. Ilość napiwków, gęstość trójglicerydów itp. Zwykle są wykonywane tylko dla jednej zmiennej

DeepDive™

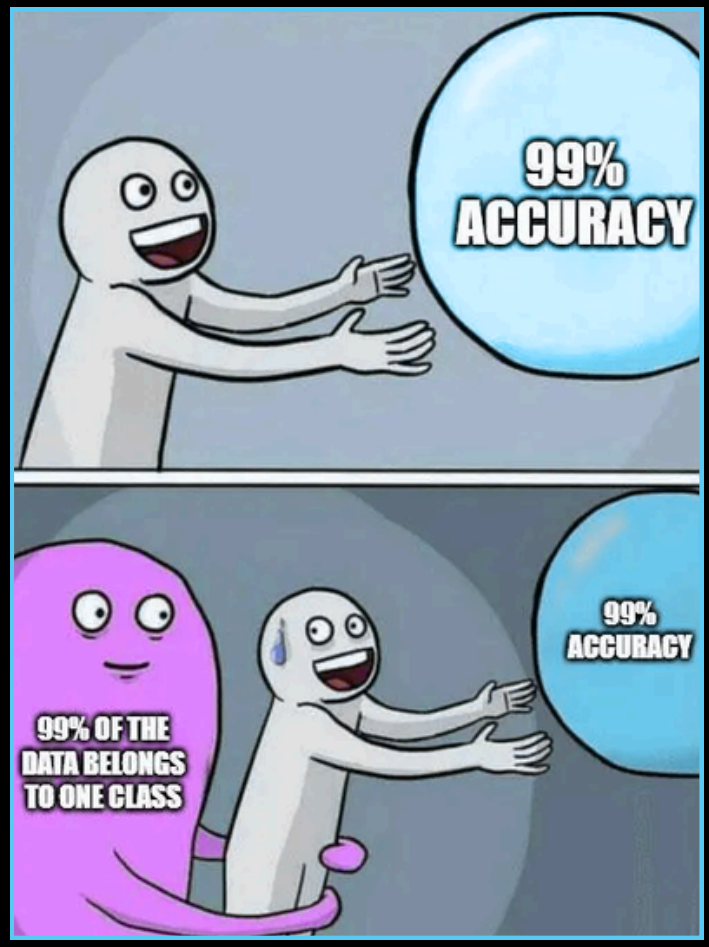
Rozkład klas

Pokazuje, **ile obserwacji należy do każdej klasy zmiennej docelowej.**

Przykład:
klasa 0 = 900 obserwacji
klasa 1 = 100 obserwacji
Więc mamy niezbalansowany zbiór danych

Dlaczego to ważne?
model może preferować klasę dominującą,
wysoka accuracy może być myląca,
trzeba sprawdzać też precision, recall, F1-score.

Jak sprawdzić?
df["target"].value_counts()
df["target"].value_counts(normalize=True)



DeepDive™

Biblioteki do analizy danych

pandas

biblioteka do wczytywania,
czyszczenia i analizy danych

Series - jedna kolumna
DataFrame - tabela

Typowe operacje:
filtrowanie i sortowanie
obsługa braków
grupowanie i agregacja
statystyki opisowe
łączenie zbiorów danych



biblioteka do wizualizacji danych

Umożliwia tworzenie m.in.:
wykresów liniowych
słupkowych
histogramów
scatter plotów
boxplotów

DeepDive™

Repozytorium

DeepDive™


DeepDive™