
DeepDive™

EDA
(Exploratory Data Analysis)



CEL:
zrozumienie rozkładu,
zależności i problemów

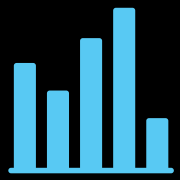


DeepDive™

EDA
(Exploratory Data Analysis)



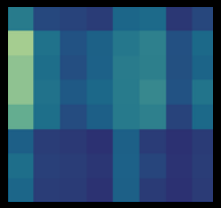
statystyki opisowe



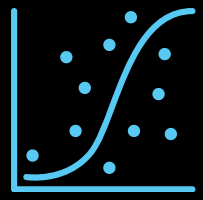
rozkłady, histogramy



rozkład klas

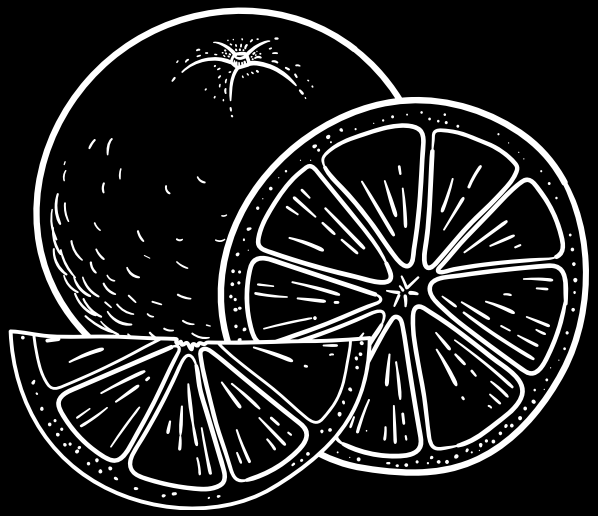


korelacje



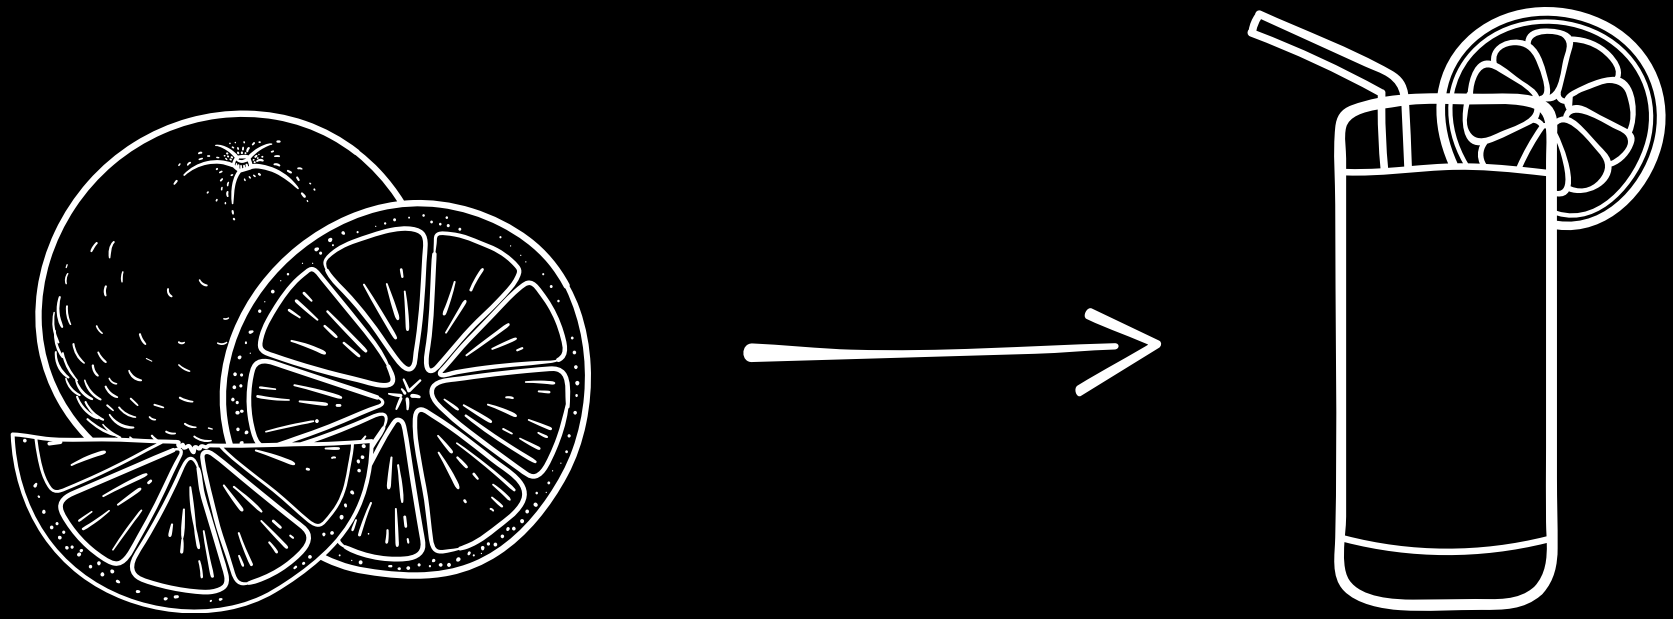
wizulizacje outlierów
(boxplot, scatter plot)

DeepDive™



DeepDive™

Redukcja wymiarów = wyciskarka



DeepDive™

Po co nam redukcja wymiarów?



DeepDive™


Wizualizacja danych w 2D/3D
Przyspieszenie obliczeń
Lepsze zrozumienie struktury danych i ich wzorców
Redukcja wymiarów
Usuwanie szumu
Kompresja danych
Eliminacja redundancji

DeepDive™

Klątwa wielowymiarowości



DeepDive™

Klątwa wielowymiarowości

Wraz ze wzrostem liczby wymiarów:

dane stają się coraz rzadsze,

odległości między punktami tracą sens,

modele uczą się wolniej i łatwiej przeuczyć model,
rośnie koszt obliczeniowy.

DeepDive™

Metody liniowe

PCA
(Principal Component Analysis)

najpopularniejsza, przekształca
dane w nowe, ortogonalne osie
maksymalnej wariancji

LDA
(Linear Discriminant Analysis)

uwzględnia przynależność do klas
optymalna dla klasyfikacji

ICA
(Independent Component Analysis)

szuka komponentów statystycznie
niezależnych

DeepDive™

Metody nieliniowe

t-SNE
(t-distributed Stochastic Neighbor Embedding)

świetna do wizualizacji, zachowuje lokalną strukturę danych

UMAP
(Uniform Manifold Approximation and Projection)

szybsze od t-SNE, zachowuje więcej globalnej struktury

Isomap
oparta na geodezyjnych odległościach na kolektorze danych

DeepDive™

Metody oparte o uczenie maszynowe

Autoenkodery (**Autoencoders**)
sieci neuronowe uczące się kompresji danych

Feature selection (np. LASSO, SelectKBest)
wybierają najważniejsze cechy bez tworzenia nowych

DeepDive™

PRINCIPAL COMPONENT ANALYSIS

Analiza składowych głównych (PCA)

liniowa metoda redukcji wymiarów

Tworzy nowe zmienne - składowe główne (principal components) jako kombinacje liniowe oryginalnych cech.

A każda kolejna składowa wyjaśnia możliwie dużo zmienności danych oraz jest prostopadła do poprzednich.

PC1 wyjaśnia największą część wariancji, PC2 największą część pozostałej wariancji, potem PC3, PC4 itd.



DeepDive™

Jak działa PCA?



DeepDive™

1. Standaryzacja danych
2. Obliczenie macierzy kowariancji/korelacji
3. Wyznaczenie wektorów i wartości własnych
4. Wybór składowych głównych
5. Transformacja danych

DeepDive™

Case study

Dane z Biura Statystyk Pracy ze Stanów Zjednoczonych.
Przedstawiają tygodniowe zarobki w 2020 roku z podziałem na stany.

DeepDive™

Macierz korelacji

	Transformowana liczba pracowników	Transformowana mediana zarobków	Transformowana liczba kobiet pracujących	Mediana zarobków kobiet	Transformowana ilość mężczyzn pracujących	Mediana zarobków mężczyzn
Transformowana liczba pracowników	1.000000	0.287842	0.999026	0.300256	0.999373	0.262250
Transformowana mediana zarobków	0.287842	1.000000	0.284447	0.969466	0.290151	0.969635
Transformowana liczba kobiet pracujących	0.999026	0.284447	1.000000	0.299753	0.996842	0.260402
Mediana zarobków kobiet	0.300256	0.969466	0.299753	1.000000	0.300320	0.901497
Transformowana ilość mężczyzn pracujących	0.999373	0.290151	0.996842	0.300320	1.000000	0.263151
Mediana zarobków mężczyzn	0.262250	0.969635	0.260402	0.901497	0.263151	1.000000

DeepDive™

Wektory i wartości własne

	Wektory własne					
Transformowana liczba pracowników	-0.419575	-0.396923	0.010384	0.019246	-0.814499	0.050215
Transformowana mediana zarobków	-0.403576	0.425013	-0.003109	0.735537	-0.002831	-0.339790
Transformowana liczba kobiet pracujących	-0.418716	-0.397564	0.000062	-0.305947	0.361194	-0.665248
Mediana zarobków kobiet	-0.398912	0.406232	-0.709910	-0.373295	0.000774	0.180341
Transformowana ilość mężczyzn pracujących	-0.419611	-0.395872	0.016430	0.284961	0.454001	0.616135
Mediana zarobków mężczyzn	-0.388015	0.426637	0.704017	-0.380078	0.002155	0.165289
Wartości własne	3.884728	2.006370	0.098145	0.008493	0.000001	0.002262
% Wyjaśnianej wariancji	64,75 %	33,43 %	1,64 %	0,14 %	0,00025 %	0,04 %

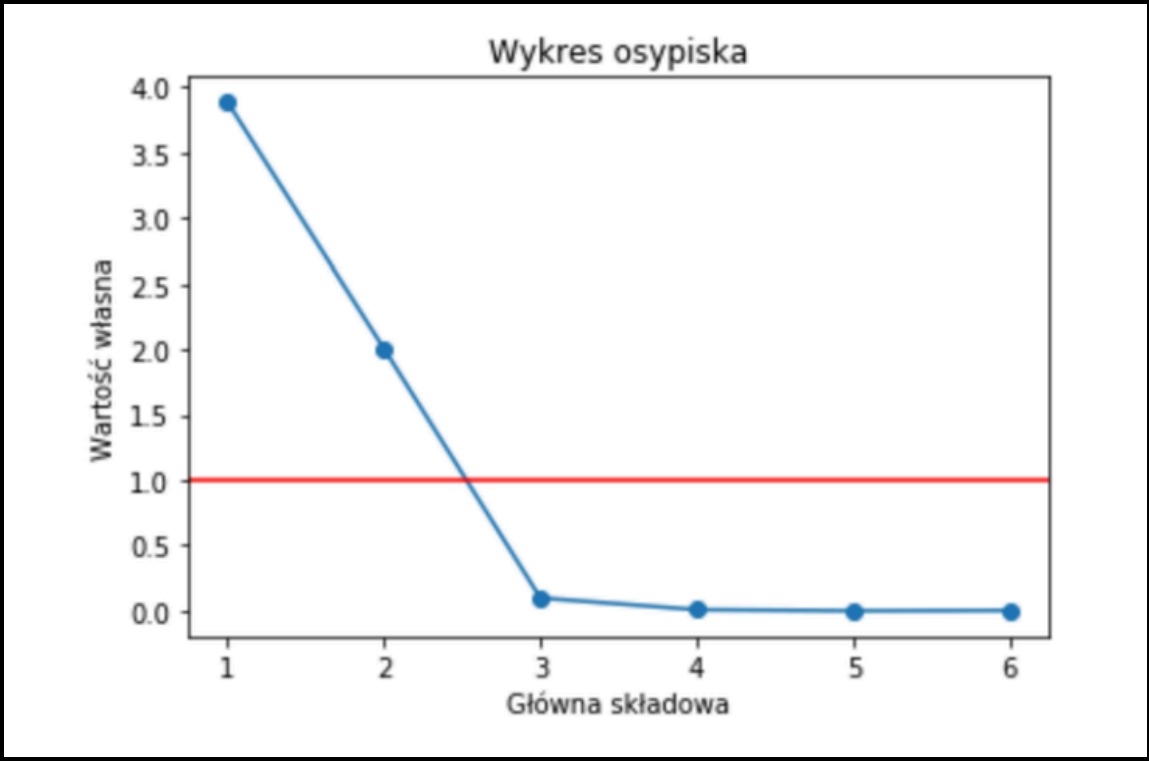
DeepDive™

Macierz ładunków czynnikowych

	PC1	PC2	PC3	PC4	PC5	PC6
Transformowana liczba pracowników	-0.826970	-0.795437	-0.825277	-7.862446e-01	-0.827041	-0.764767
Transformowana mediana zarobków	-0.562228	0.602016	-0.563135	5.754130e-01	-0.560739	0.604316
Transformowana liczba kobiet pracujących	0.003253	-0.000974	0.000020	-2.224010e-01	0.005147	0.220555
Mediana zarobków kobiet	0.001774	0.067786	-0.028195	-3.440211e-02	0.026261	-0.035027
Transformowana ilość mężczyzn pracujących	-0.000991	-0.000003	0.000439	9.412193e-07	0.000552	0.000003
Mediana zarobków mężczyzn	0.002388	-0.016162	-0.031641	8.577637e-03	0.029305	0.007862

DeepDive™

Wybór ilości głównych składowych



kryterium osypiska (1966)

kryterium Kaisera (1960)

kryterium minimalnego zasobu wyjaśnianej zmienności (>70%)

64.75 % + 33.43 % = 98.18 %

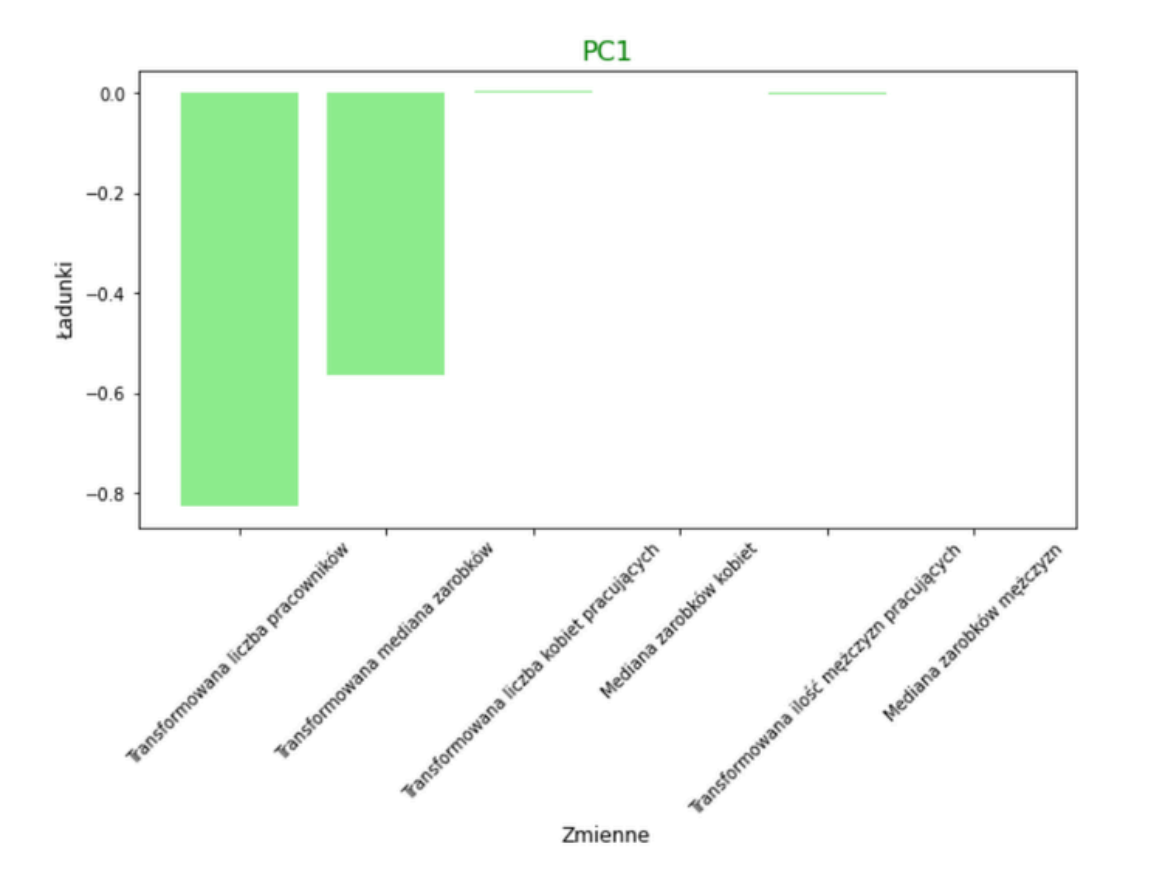
DeepDive™

Wybór ilości głównych składowych

	PC1	PC2
Transformowana liczba pracowników	-0.826970	-0.795437
Transformowana mediana zarobków	-0.562228	0.602016
Transformowana liczba kobiet pracujących	0.003253	-0.000974
Mediana zarobków kobiet	0.001774	0.067786
Transformowana ilość mężczyzn pracujących	-0.000991	-0.000003
Mediana zarobków mężczyzn	0.002388	-0.016162

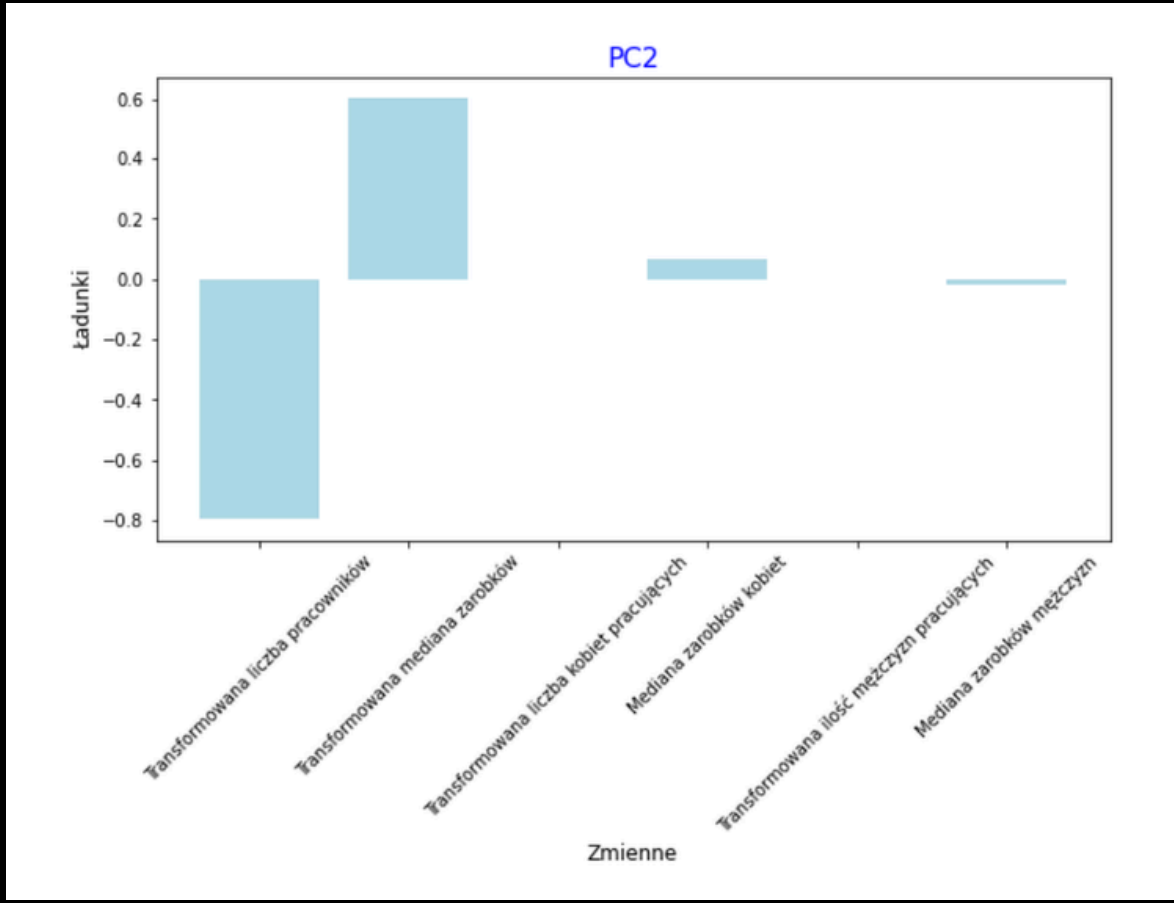
DeepDive™

Wykres ładunków czynnikowych



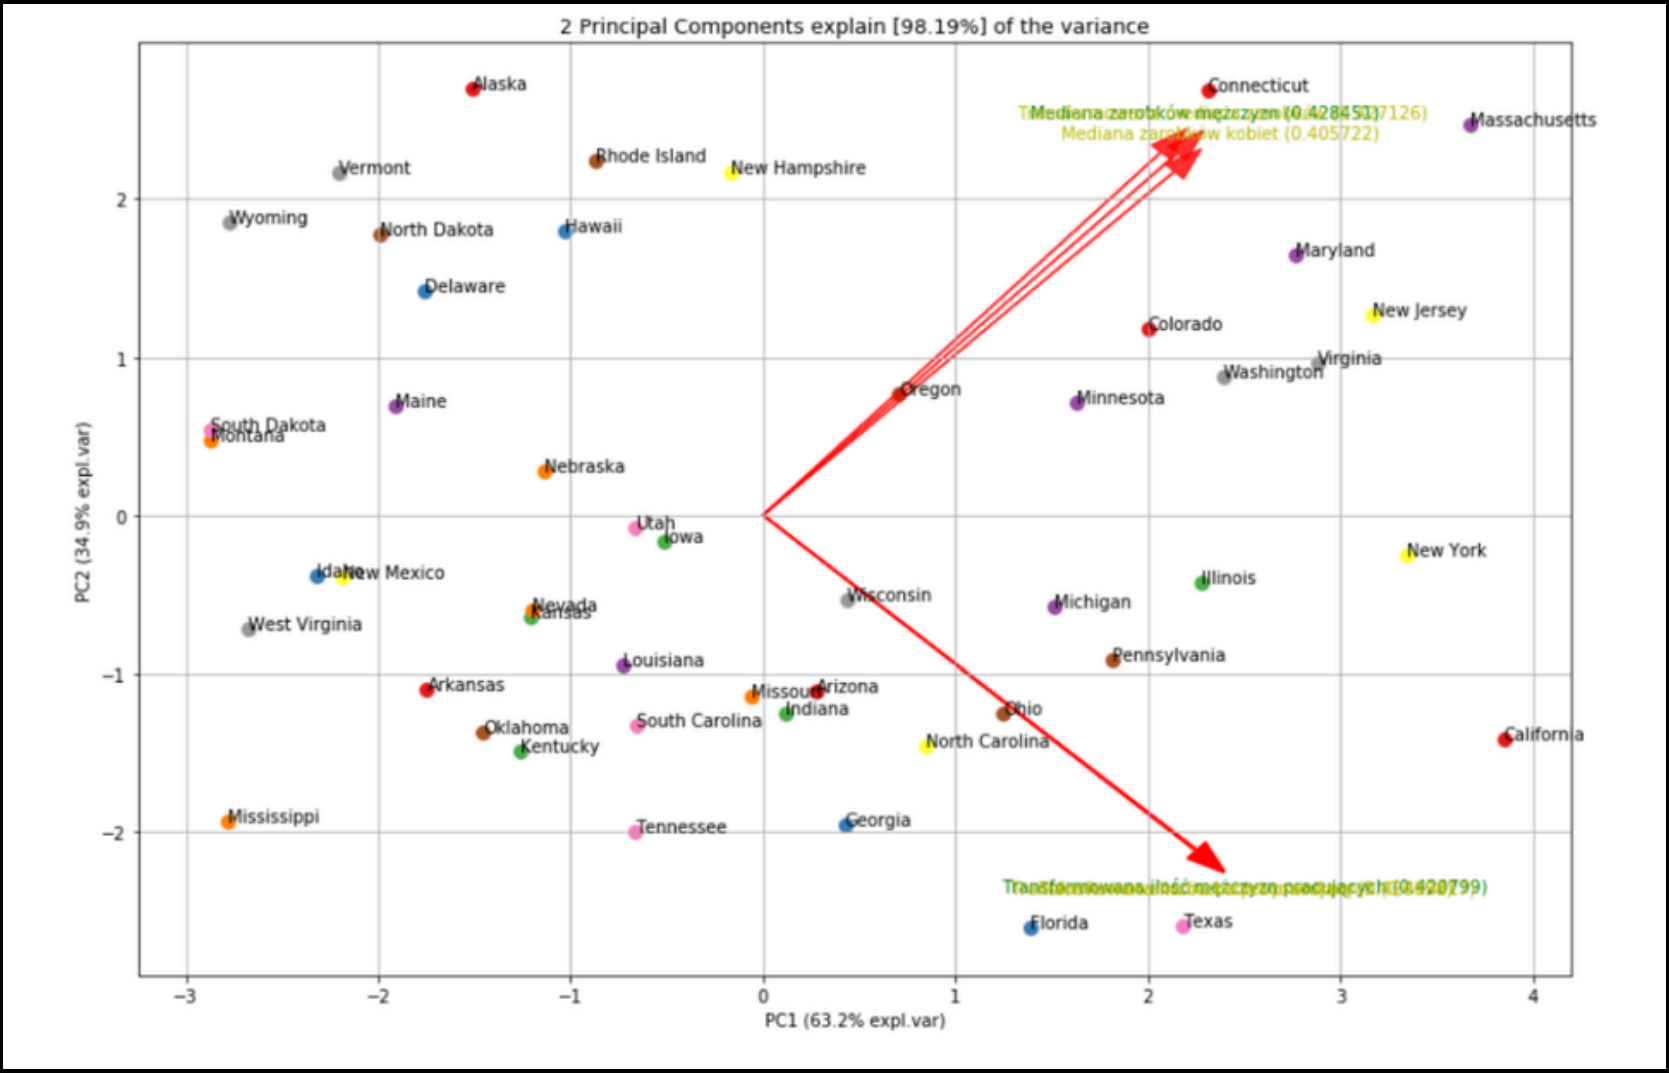
DeepDive™

Wykres ładunków czynnikowych



DeepDive™

Biplot



DeepDive™

Wnioski

PC1 silnie zależy od zarobków (kobiet i mężczyzn) – rozróżnia stany bogatsze i biedniejsze.

PC2 związany z udziałem pracujących mężczyzn.

Connecticut, Massachusetts, New Jersey – wysokie zarobki.

Texas, Florida, Georgia – więcej pracujących mężczyzn, ale niższe zarobki.

PCA ujawnia naturalne klastry stanów wg cech społeczno-ekonomicznych.

DeepDive™

Jak działa t-SNE?



DeepDive™

t-Distributed Stochastic Neighbor Embedding

stochastyczna metoda porządkowania sąsiadów
w oparciu o rozkład t



DeepDive™



zachowuje lokalne struktury danych,
ale niekoniecznie globalne



świetne do wizualizacji, ale nie nadaje się do predykcji



wyniki mogą się różnić przy każdym uruchomieniu
(chyba że ustawi się random_state)

DeepDive™

1. Obliczenie podobieństw między punktami w przestrzeni wysokowymiarowej
2. Losowa inicjalizacja punktów w przestrzeni 2D lub 3D
3. Obliczenie podobieństw między punktami w niskim wymiarze
4. Minimalizacja różnicy między tymi dwoma rozkładami podobieństw
5. Przemieszczanie punktów w 2D, aż rozkłady będą jak najbardziej zbliżone

DeepDive™

Perplexity

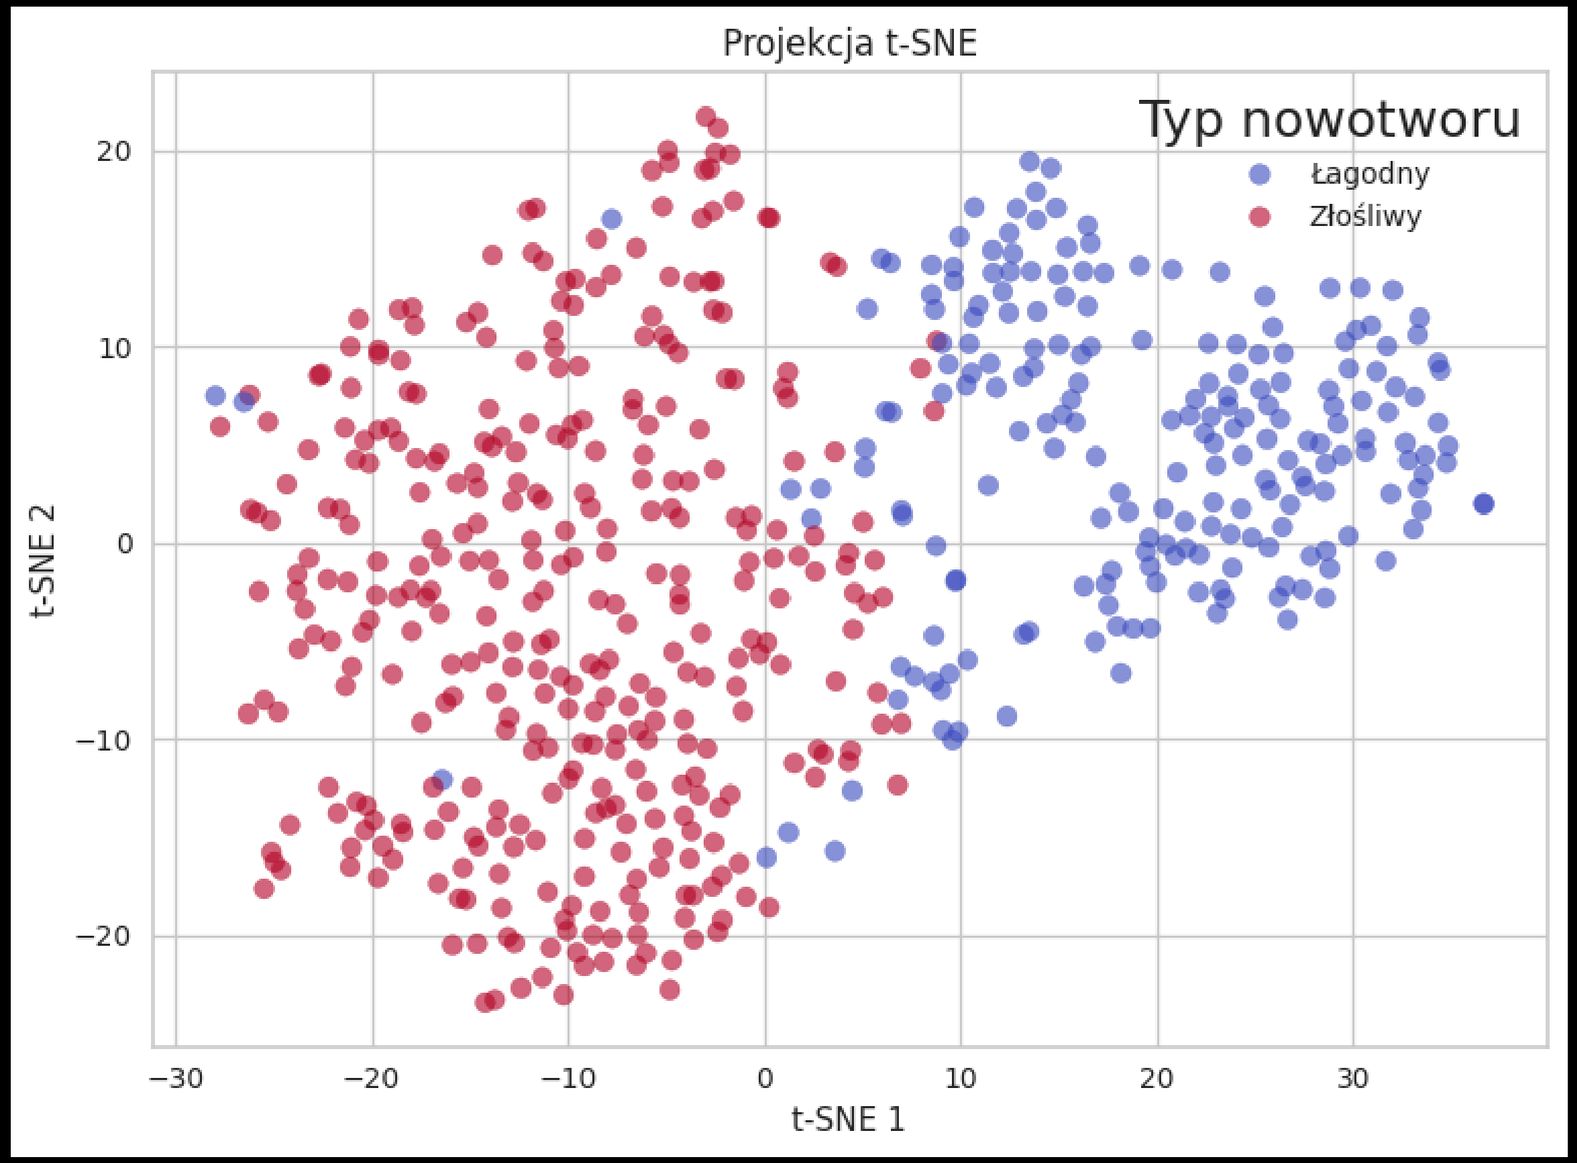
Mała wartość (5–30):

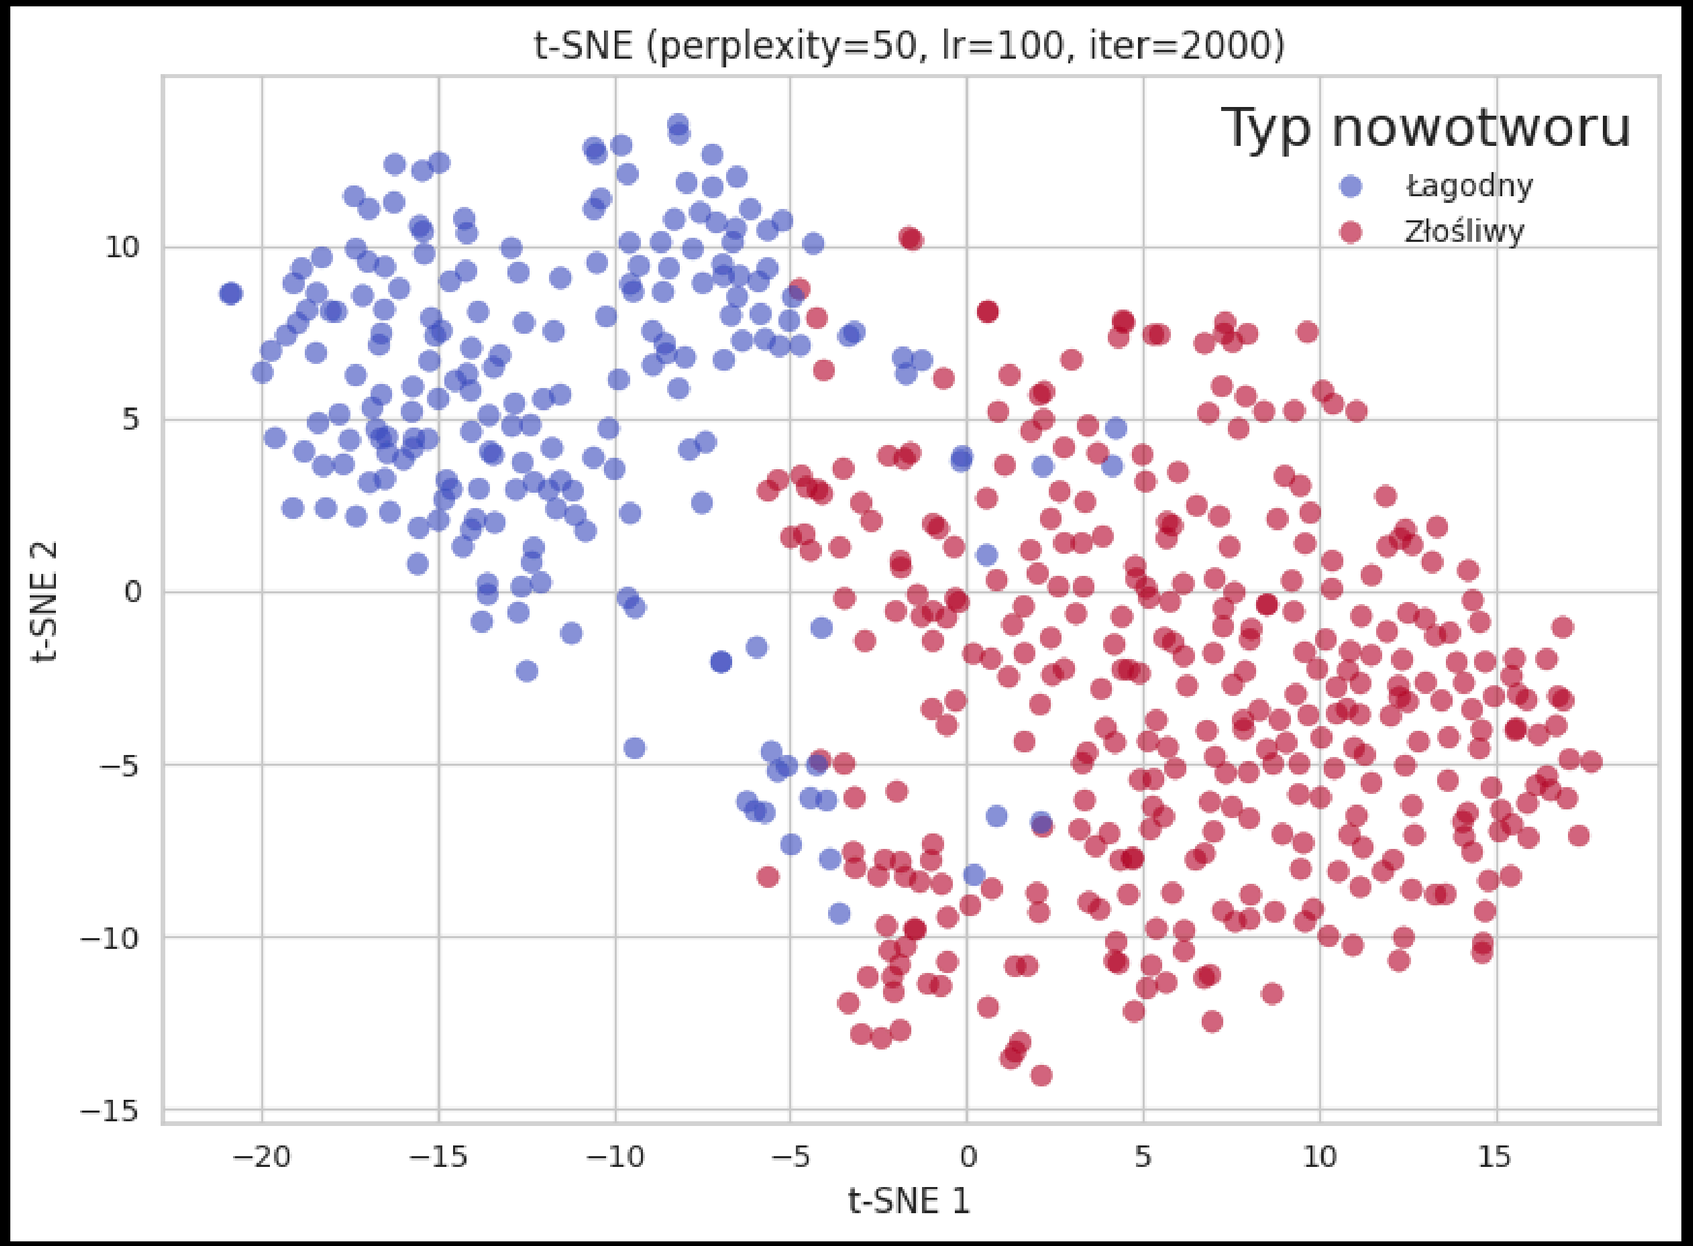
t-SNE skupia się bardziej na lokalnej strukturze danych.
Może uwydatnić małe klastry.
Większe ryzyko szumu i przetrenowania.

Większa wartość (50–100):

t-SNE patrzy szerzej, uwzględnia więcej sąsiadów.
Zachowuje więcej globalnej struktury.
Może spłaszczyć lokalne różnice.

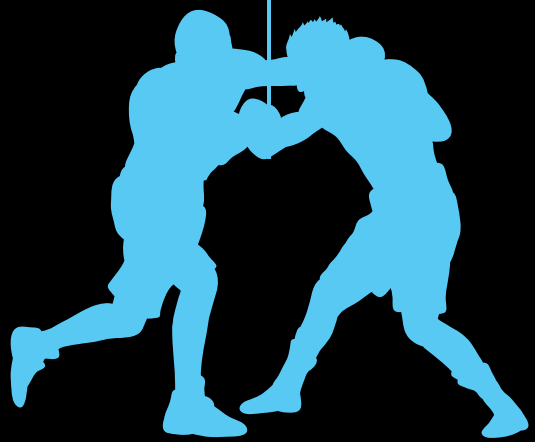
DeepDive™


Projekcja t-SNE
Typ nowotworu
Łagodny
Złośliwy
t-SNE 2
t-SNE 1
20
10
0
−10
−20
−30
−20
−10
0
10
20
30


t-SNE (perplexity=50, lr=100, iter=2000)
Typ nowotworu
Łagodny
Złośliwy
t-SNE 2
t-SNE 1
10
5
0
−5
−10
−15
−20
−15
−10
−5
0
5
10
15

PCA vs t-SNE

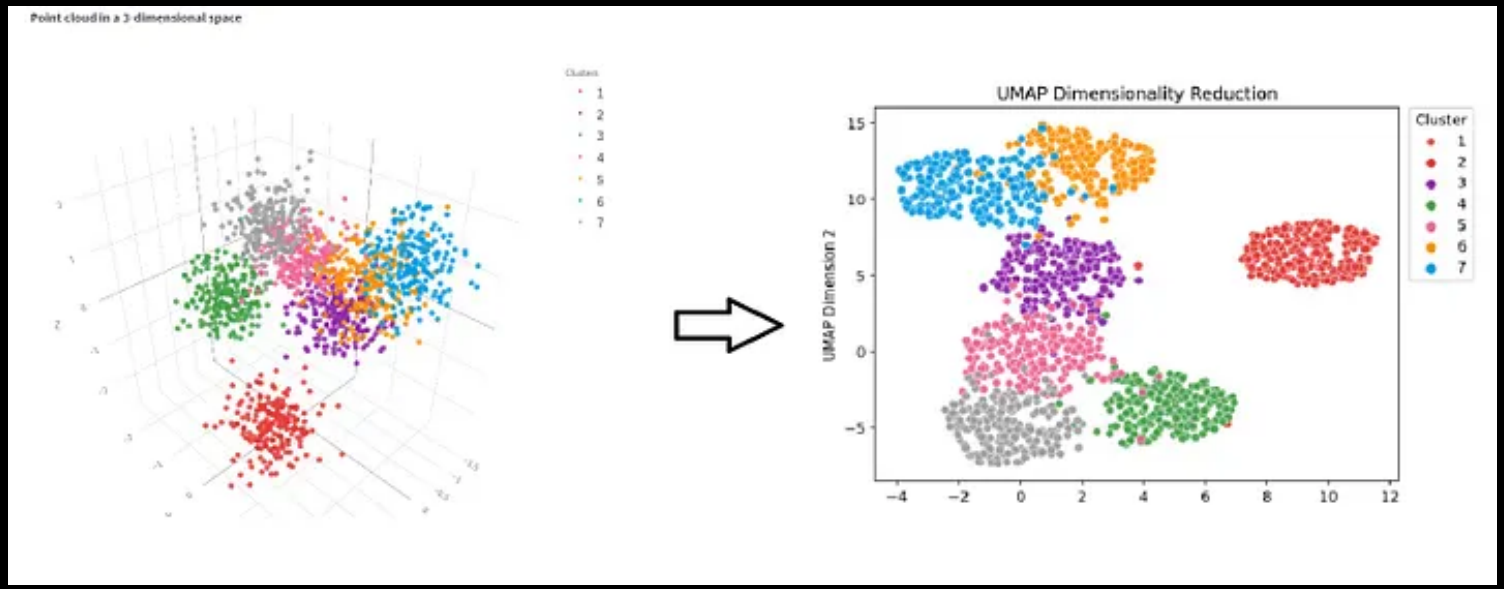
PCA	t-SNE
szybki, liniowy, deterministyczny	wolniejszy, nieliniowy, probabilistyczny
zachowuje globalną strukturę (maksymalizuje wariancję)	lepiej oddaje lokalne podobieństwa
szybka redukcja wymiarów	wizualizacja złożonych zbiorów danych



DeepDive™

UMAP

UMAP (Uniform Manifold Approximation and Projection) to metoda redukcji wymiarów.
Służy do przedstawienia danych wysokowymiarowych w 2D lub 3D.
Stara się zachować przede wszystkim lokalną strukturę danych.



https://medium.com/mcd-unison/umap-an-alternative-dimensionality-reduction-technique-7a5e77e80982

UMAP buduje najpierw graf sąsiedztwa:
dla każdego punktu szuka jego najbliższych sąsiadów, zapisuje relacje podobieństwa, a potem próbuje odwzorować te relacje w 2D/3D.

n_neighbors – im mniejsza tym większy nacisk na lokalne grupy
min_dist – im większe tym bardziej rozproszone grupy

DeepDive™


DeepDive™