
DeepDive™

Czym jest klastrowanie?



DeepDive™

Klastrowanie

grupowanie podobnych obserwacji w klastry,
bez wcześniej podanych etykiet



Po co klastrować?

→ odkrywanie naturalnych grup w danych
→ wykrywanie podobnych wzorców
→ pomoc w analizie danych bez etykiet

Czym jest podobieństwo?

Podobieństwo w klastrowaniu mówi, jak bardzo dwie obserwacje są do siebie zbliżone **na podstawie ich cech**.

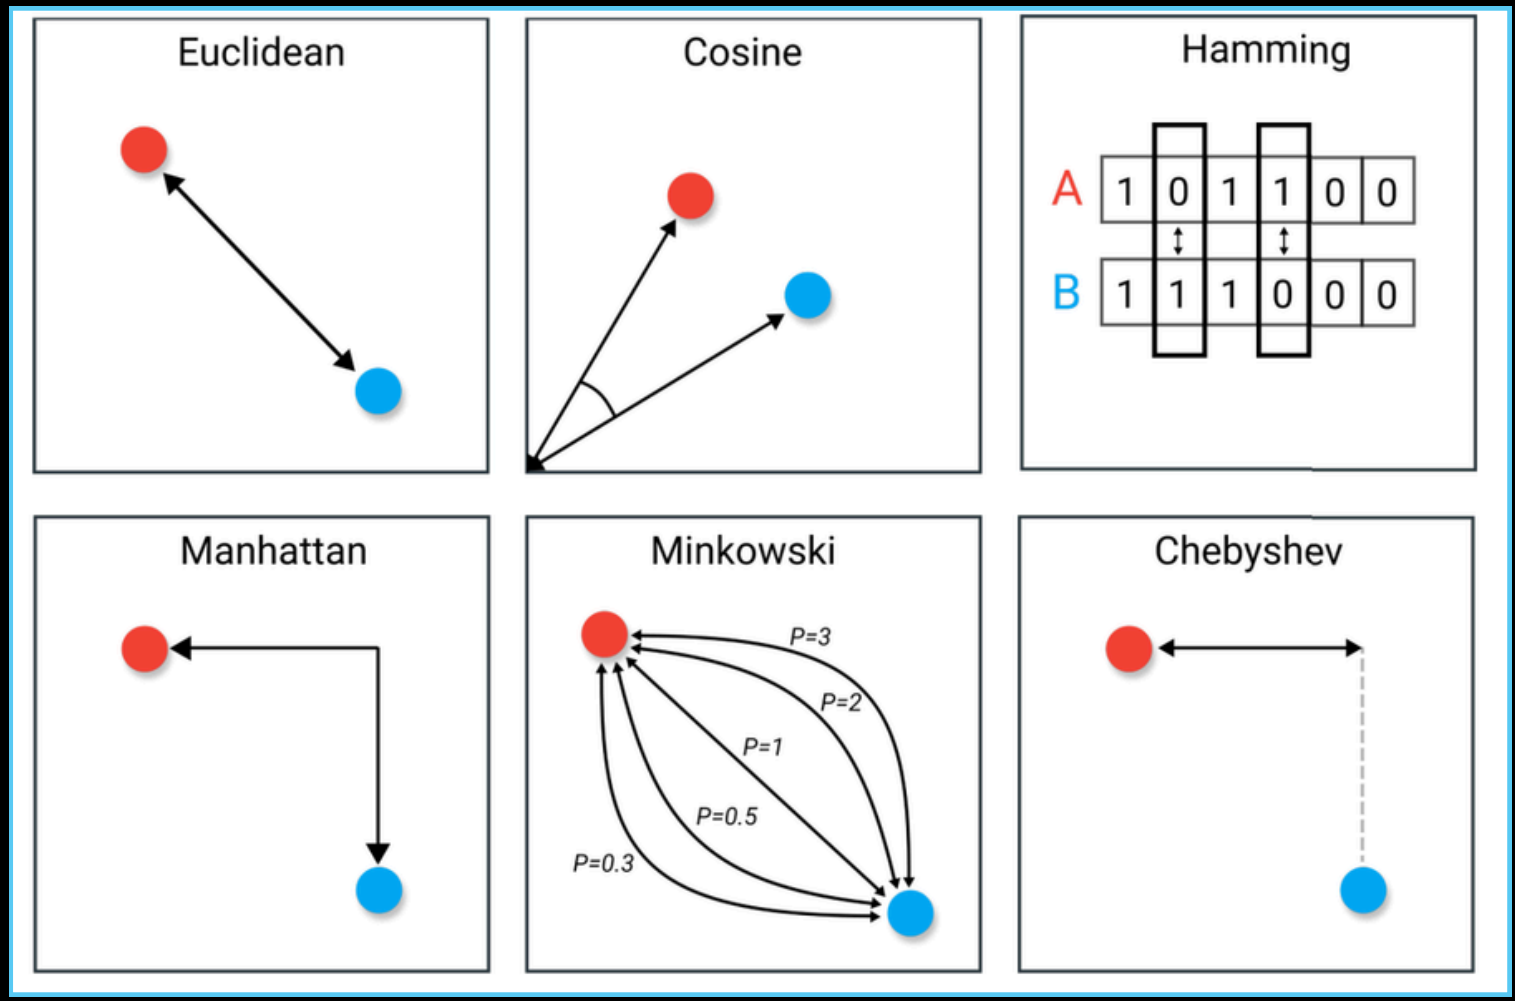
Wynik klasteryzacji zależy od:

- wybranych cech,
- skali cech,
- metryki odległości,
- reprezentacji danych,
- algorytmu.

Klaster = grupa obiektów bardziej podobnych do siebie niż do obiektów spoza grupy.

DeepDive™

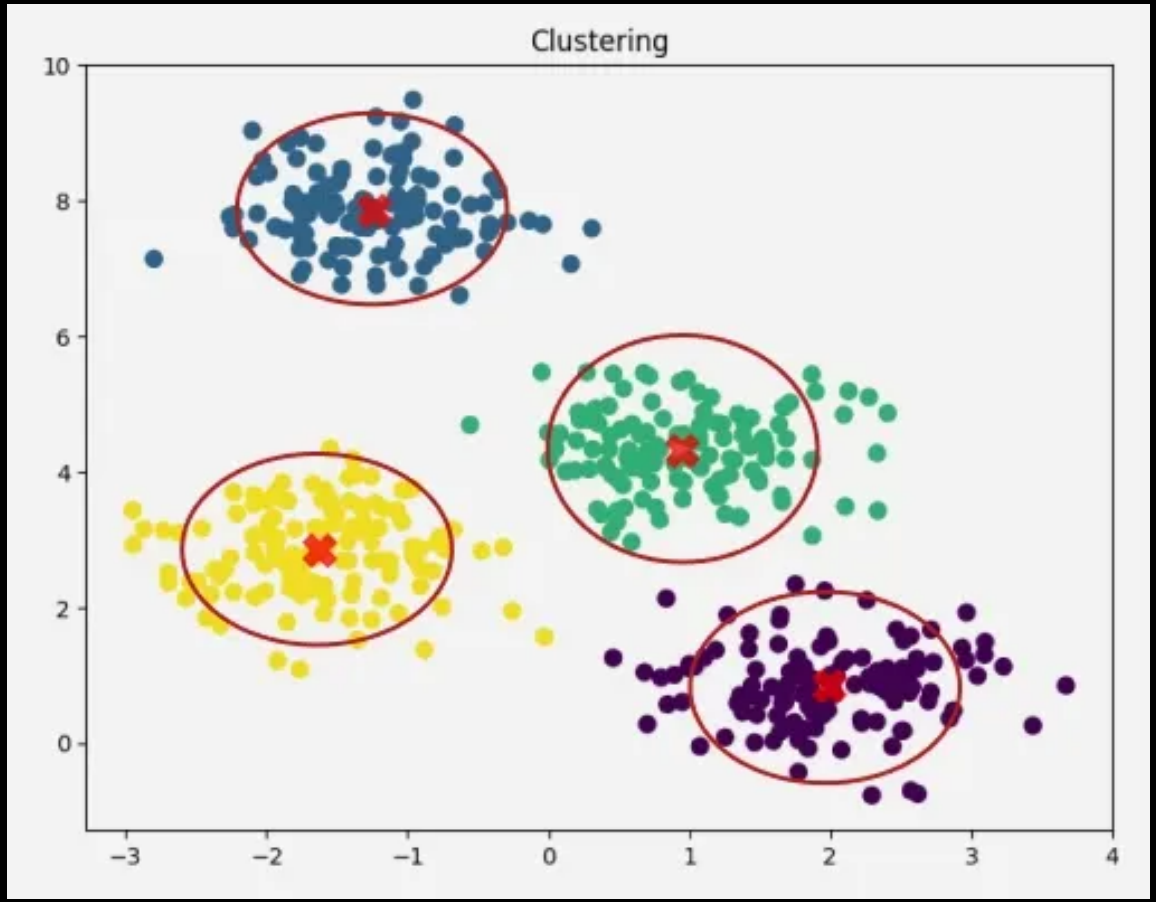
Miary odległości



https://www.maartengrootendorst.com/blog/distances/

DeepDive™

Klastrowanie



https://www.geeksforgeeks.org/machine-learning/clustering-in-machine-learning/

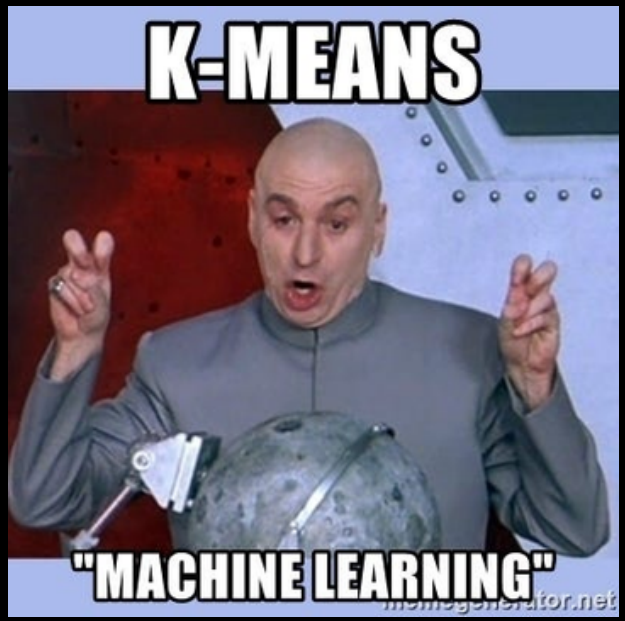


Klasteryzacja nie odpowiada na pytanie „do której znanej klasy należy ten obiekt?”,
tylko raczej „czy w tych danych naturalnie pojawiają się jakieś grupy?”

DeepDive™

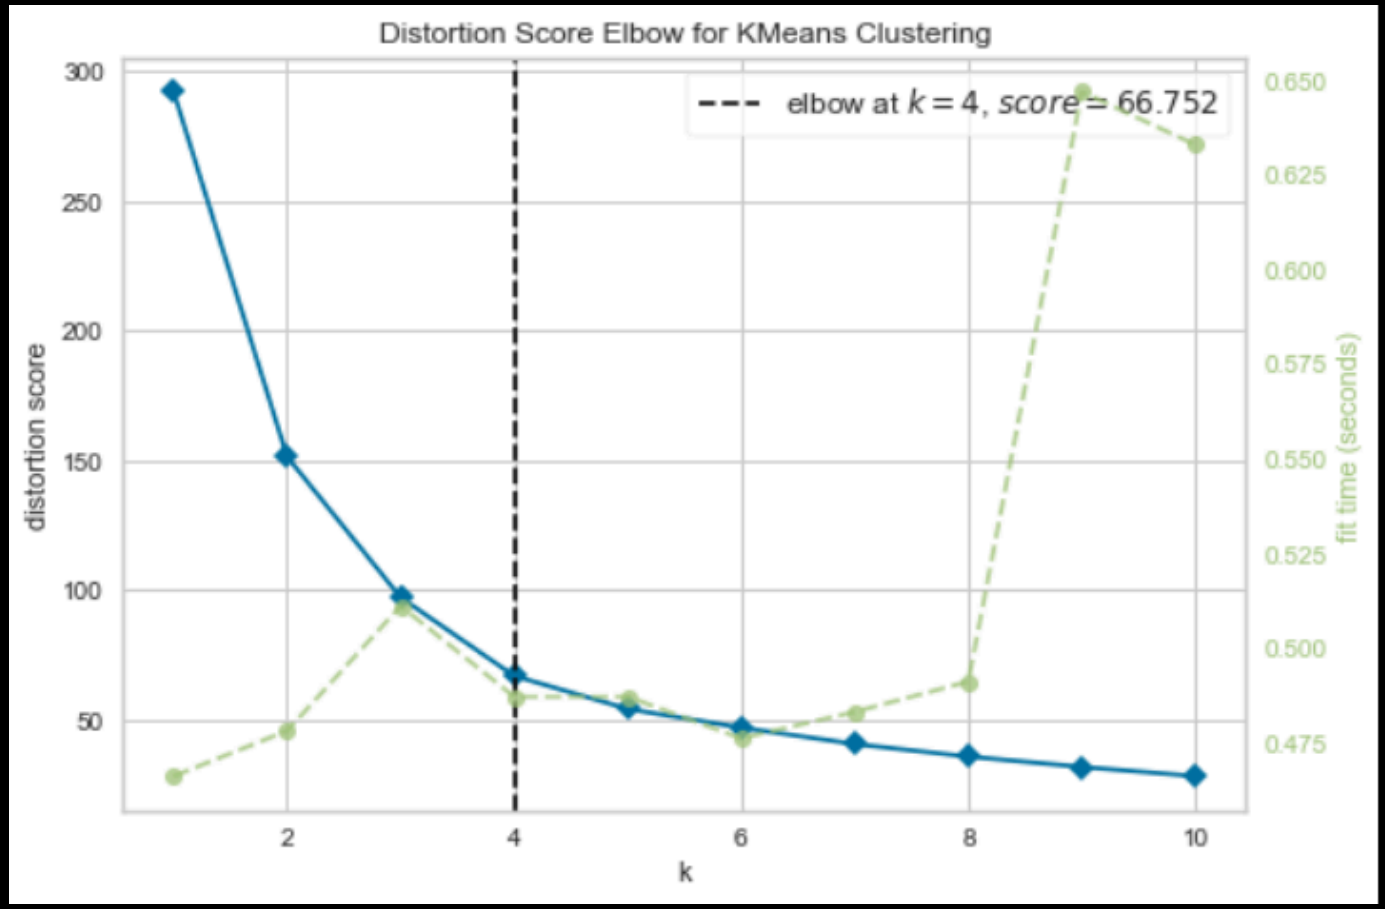
Algorytm k-średnich

Metoda k-średnich jest metodą uczenia maszynowego bez nadzoru.
W podstawie leży taki dobór klastrów, aby łączna wariancja wszystkich klastrów była minimalna.
Wariancję tę określa się poprzez sumę kwadratów odległości pomiędzy każdą z obserwacji, a środkiem danego klastra.



DeepDive™

Dobór ilości klastrów



Metoda punktu łokcia
(elbow method)

DeepDive™

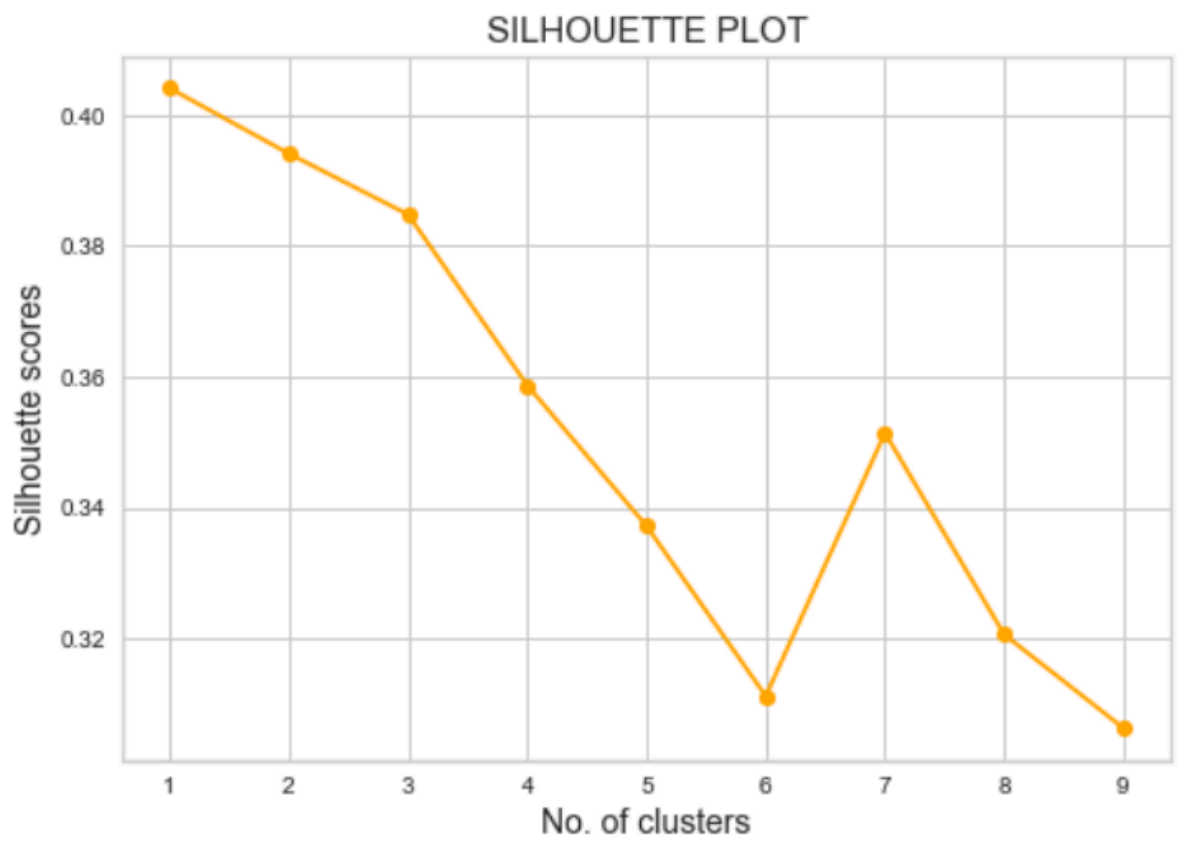
Dobór ilości klastrów

Metoda punktu łokcia
(elbow method)

Wykres to suma kwadratów odległości poszczególnych obserwacji
od centroidów w funkcji ilości klastrów.
Zasada wyboru na podstawie wykresu jest bardzo podobna
do wykresu osypiska stosowanego w analizie głównych składowych –
wybieramy **takie k, dla którego wykres przestaje gwałtownie spadać,**
a następne wartości są już do siebie zbliżone.

DeepDive™

Dobór ilości klastrów



Metoda profilu
(silhouette method)

DeepDive™

Dobór ilości klastrów

Wartości wskaźnika sylwetki otrzymane dla metody profilu:
Dla k = 2 klastrów, Silhouette Score jest równy 0.4041
Dla k = 3 klastrów, Silhouette Score jest równy 0.3941
Dla k = 4 klastrów, Silhouette Score jest równy 0.3848
Dla k = 5 klastrów, Silhouette Score jest równy 0.3587
Dla k = 6 klastrów, Silhouette Score jest równy 0.3372
Dla k = 7 klastrów, Silhouette Score jest równy 0.3112
Dla k = 8 klastrów, Silhouette Score jest równy 0.3514
Dla k = 9 klastrów, Silhouette Score jest równy 0.3206
Dla k = 10 klastrów, Silhouette Score jest równy 0.3063

Metoda profilu
(silhouette method)

DeepDive™

Dobór ilości klastrów

Metoda profilu
(silhouette method)

Wskaźnik sylwetki mówi o tym, jak poszczególny obiekt jest podobny do pozostałych w grupie oraz jak różny jest od obiektów w pozostałych grupach.

Za optymalną liczbę klastrów uważa się tą, dla której średnia wartość sylwetki jest największa, co w tej sytuacji dałoby k=2.
Wskaźnik ocenia jakość grupowania:
wartości w przedziale **0.71-1** pokazują **silne zgrupowanie**,
0.51-0.70 umiarkowane zgrupowanie,
0.26-0.50 zgrupowanie słabe (mogło zostać wytworzone sztucznie, należy spróbować dodatkowych metod analizy),
<0.25 brak znaczącego zgrupowania.

DeepDive™

Kroki algorytmu k-średnich

1. **Ustalenie liczby skupień**

2. **Wyznaczenie wstępnych środków skupień** (wstępnymi środkami skupień są losowo wybrane obiekty spośród danych)

3. **Obliczenie odległości obiektów od środków skupień** (w tym momencie następuje wybór typu odległości)

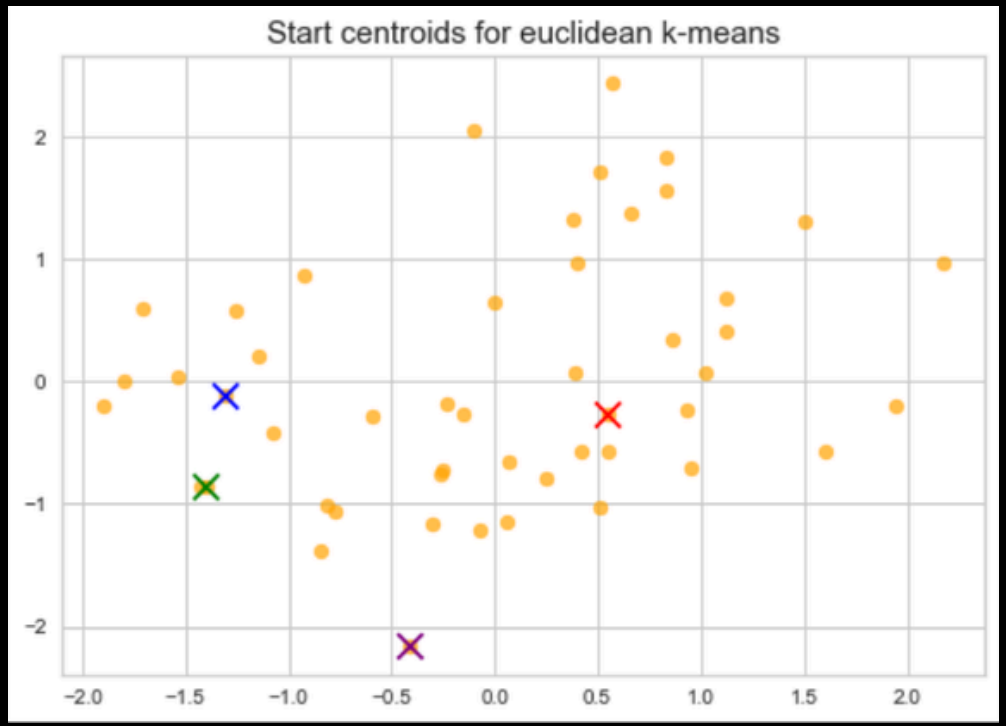
4. **Przypisanie obiektów do skupień** (obiekt zostaje przypisany do skupienia, do którego ma najmniejszą odległość)

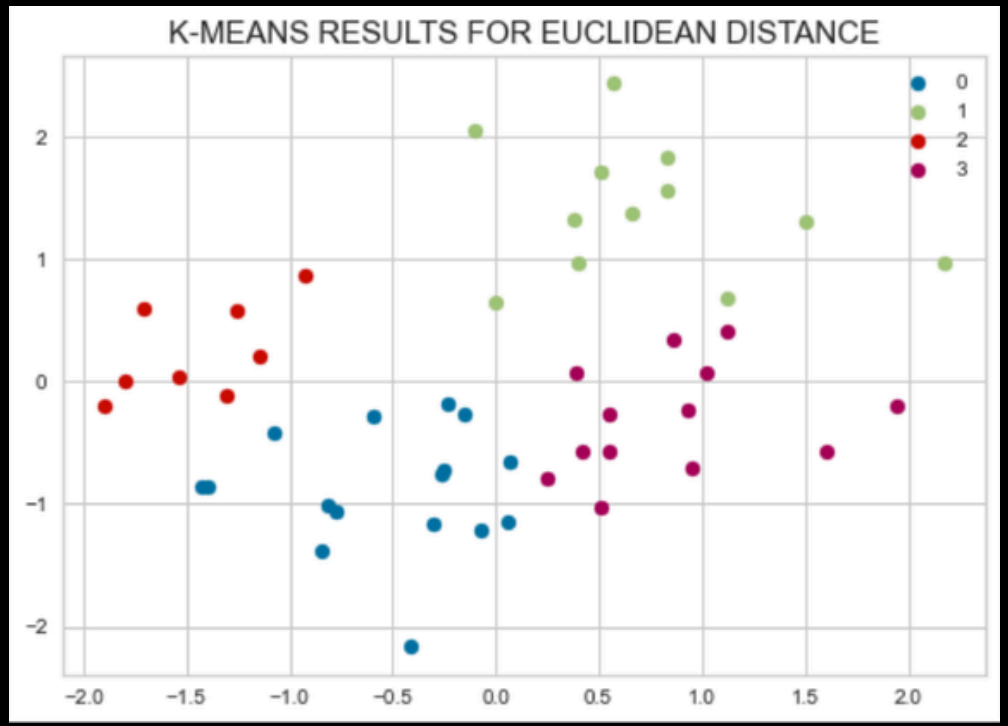
5. **Ustalenie nowych środków skupień**
(nowym centroidem jest punkt, którego współrzędne są średnią arytmetyczną współrzędnych punktów należących do danego skupienia)

Wykonywanie kroków 3,4,5 do czasu, aż warunek zatrzymania zostanie spełniony
(algorytm kończy się po wykonaniu n założonych iteracji lub gdy środki skupień przestaną się zmieniać)

DeepDive™

Przykład





DeepDive™

k-means be like:



DeepDive™

Algorytm k-średnich ++

Problem zwykłego k-means:
losowe centroidy mogą trafić bardzo blisko siebie,
co może prowadzić do słabego lokalnego rozwiązania.

K-means++
wybiera początkowe centroidy bardziej inteligentnie, ponieważ
kolejne centroidy są preferencyjnie wybierane **dalej od już istniejących.**
To zwykle daje bardziej stabilny start.

KMeans(**init**="**k-means++**")

DeepDive™

Algorytm DBSCAN

DENSITY-BASED SPATIAL CLUSTERING
OF APPLICATIONS WITH NOISE

klastry tworzone są na podstawie lokalnej gęstości punktów,
nie trzeba wcześniej podawać liczby klastrów.

K-means: gdzie są środki klastrów?

DBSCAN: gdzie znajdują się gęste obszary danych?

DeepDive™

Algorytm DBSCAN

Zalety

- **odporny na wpływ obserwacji odstających**
- **grupy o niewypukłym kształcie**
- **możliwość definiowania wielu miar odległości** – jest to problemem w przypadku np. k-średnich.

Wady

- n**ie daje możliwości definiowania** *a priori* **liczby klastrów**
- problematyczny dobór parametrów wejściowych

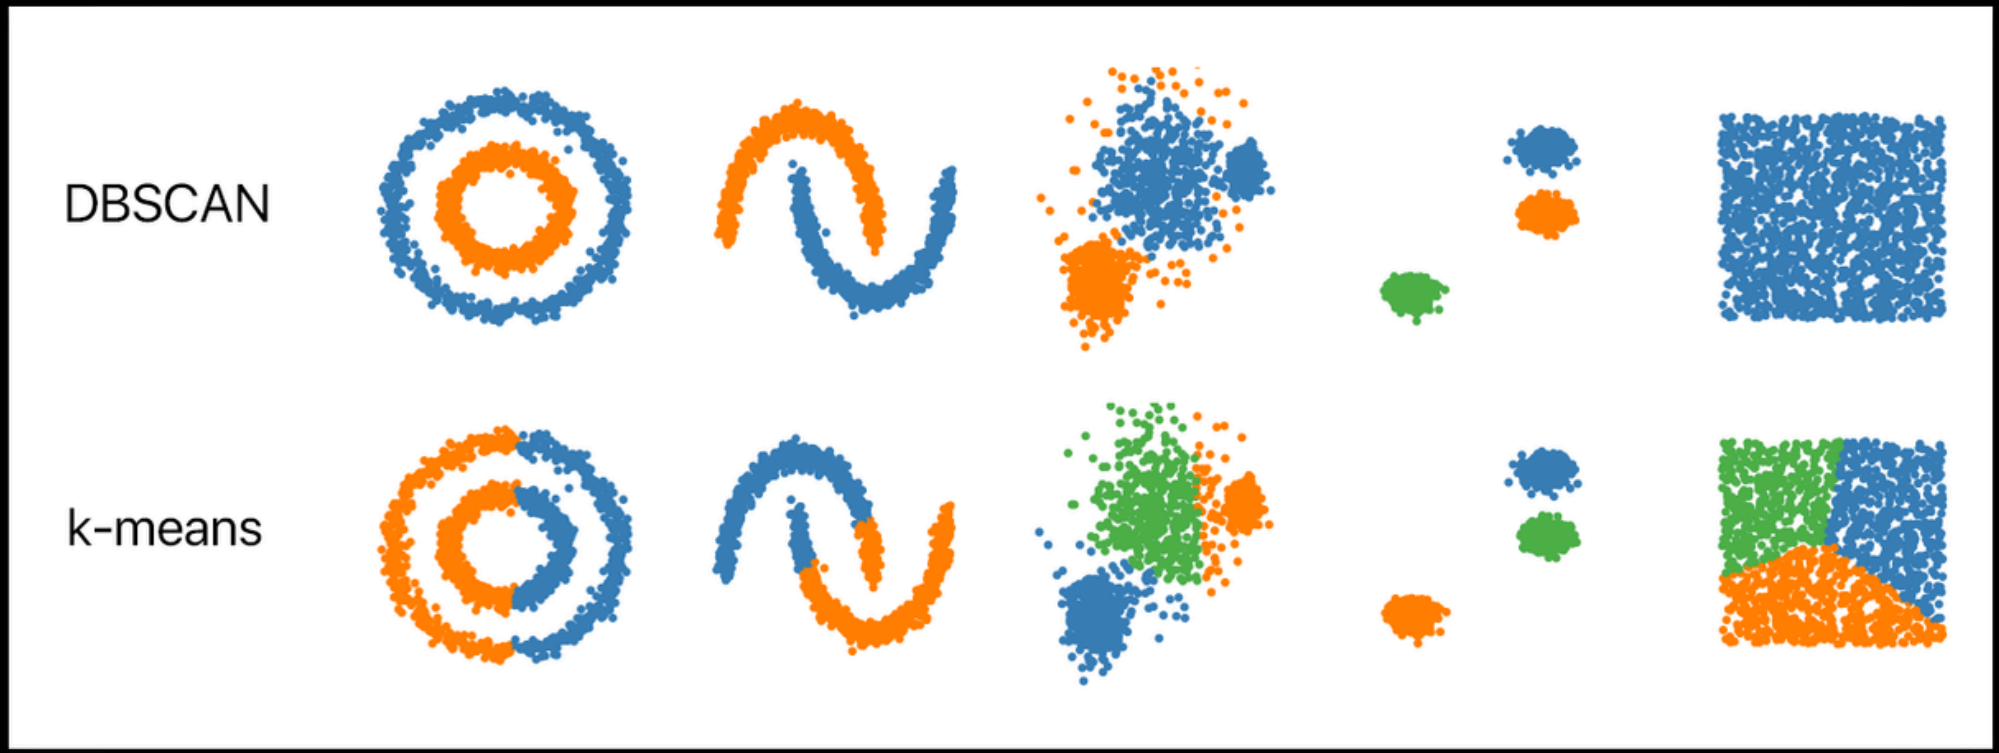
DeepDive™

Parametry wejściowe DBSCAN

epsilon (**Eps**) – promień sąsiedztwa, czyli minimalna odległość między dwiema obserwacjami, niezbędna do uznania ich za sąsiadów

min_samples (**MinPoints**) – minimalna liczba obserwacji potrzebna, aby wybrana obserwacja została uznana za punkt środkowy danej grupy (liczony jest również punkt środkowy)

DeepDive™



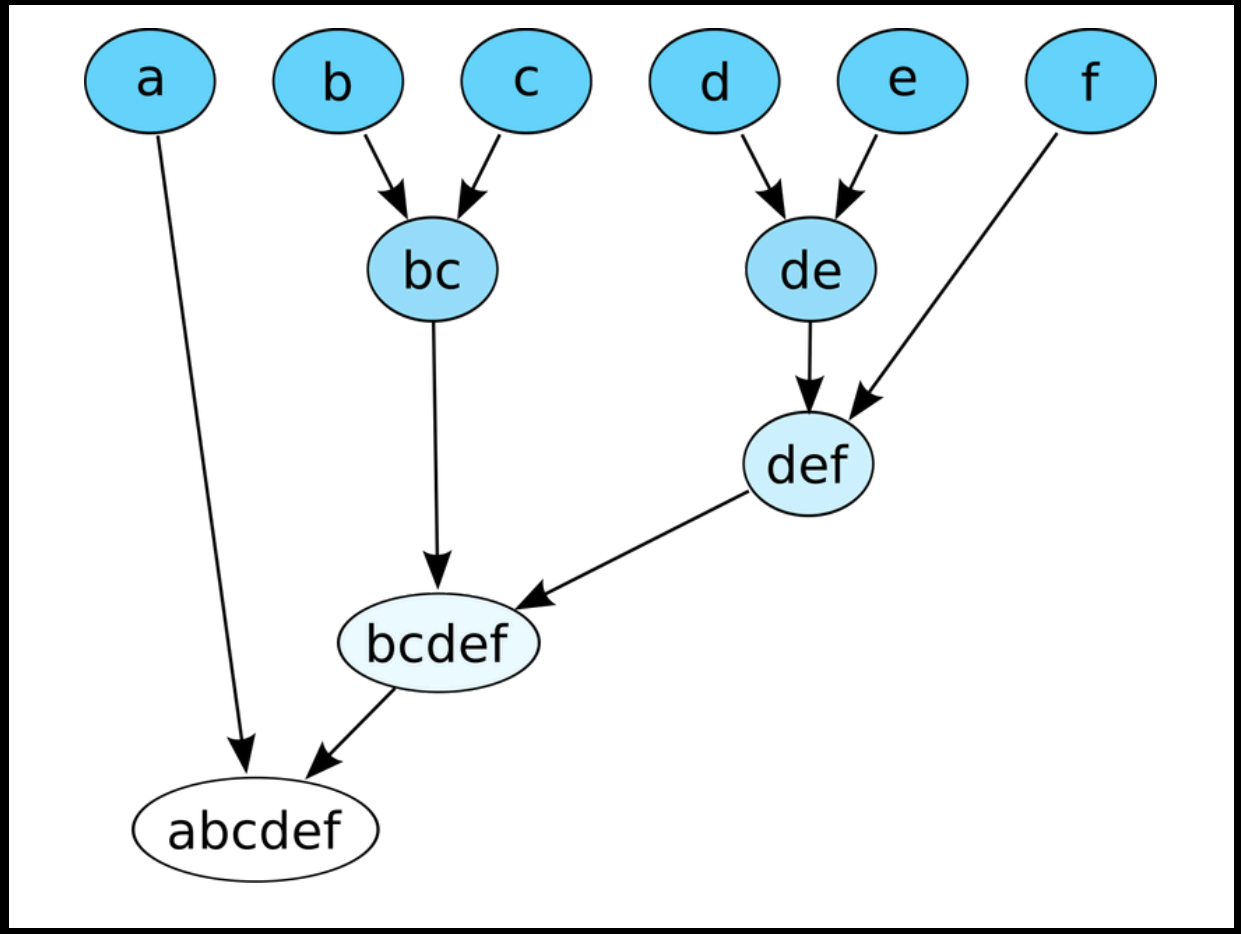
DeepDive™

Hierarchical Cluster Analysis (HCA)



DeepDive™

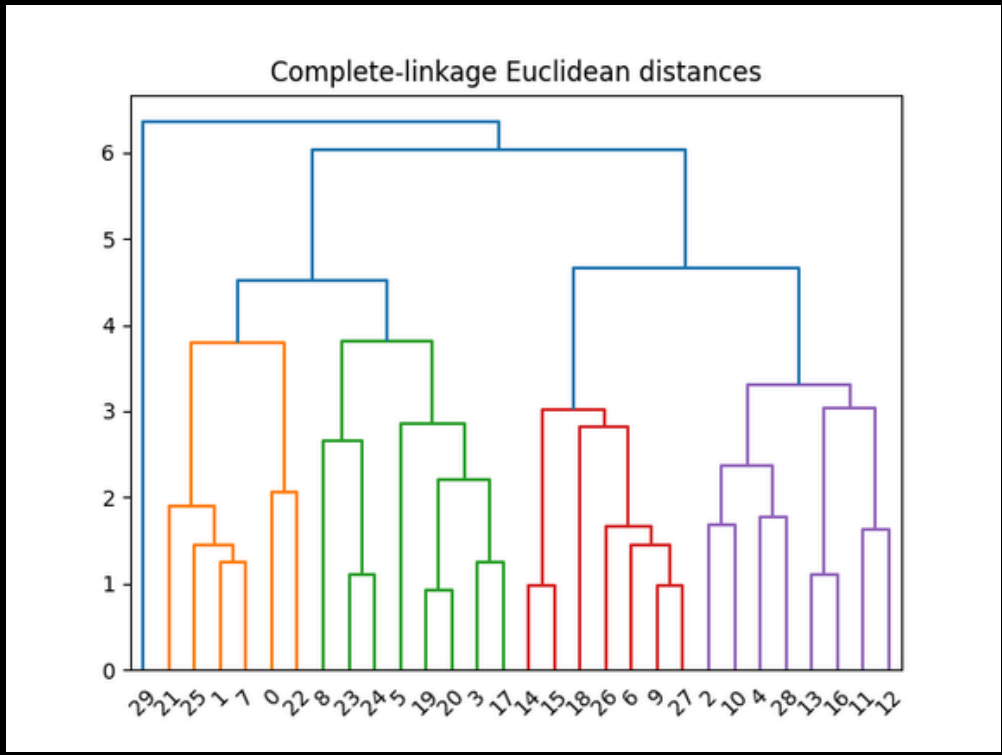
HCA - Klastrowanie Hierarchiczne

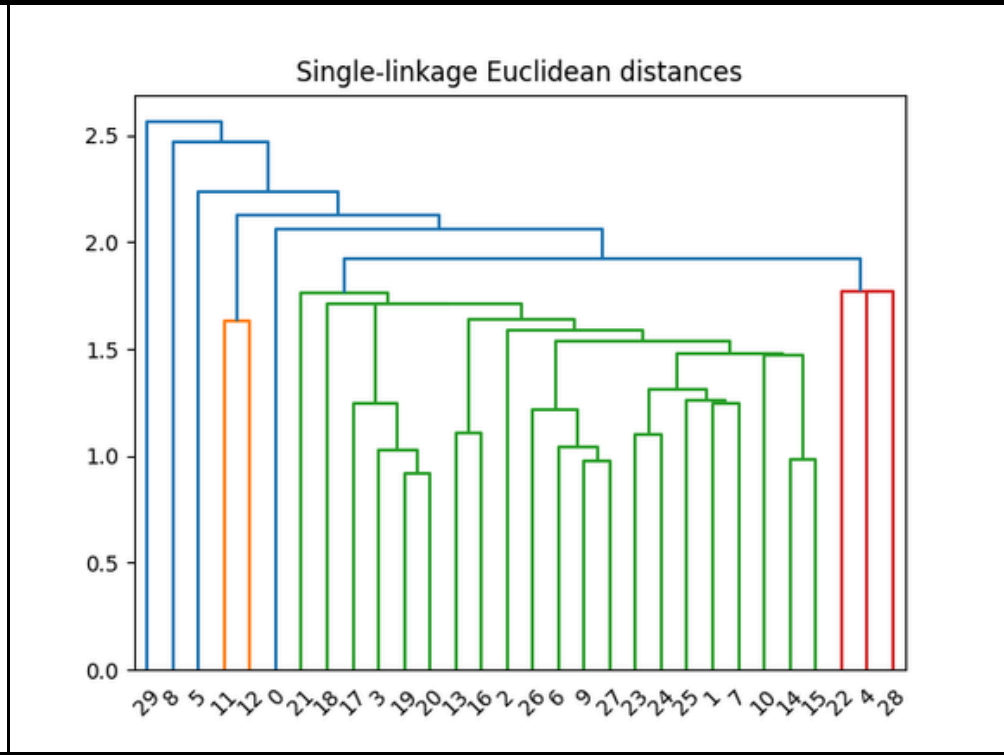


To nic innego jak grupowanie osobników o podobnych cechach, zwykle obliczając dystans między punktami.

DeepDive™

HCA – Dendrogramy





węzły – skupienia

liście – obiekty

DeepDive™

HCA - Metody łączenia

Single linkage (metoda najbliższego sąsiada) –
odległość między dwoma klastrami to najmniejsza odległość między ich elementami.

Complete linkage (metoda najdalszego sąsiada) –
używa największej odległości między elementami klastrów.

Metoda Warda –
minimalizuje wzrost wariancji wewnątrz klastrów po połączeniu.

DeepDive™

HCA – Metody łączenia

Single linkage – dobre, gdy klastry są wydłużone albo nieregularne, ale potrafi połączyć wszystko w jedno

Complete linkage – super, gdy chcesz mieć ładne, zwarte grupy i wyraźne granice; jeśli masz odstające punkty to działa gorzej

Average linkage – coś pomiędzy single a complete, sensowne, zbalansowane klastry, bezpieczny wybór

Ward – najlepsza, gdy masz dane liczbowe i chcesz, żeby klastry były jak najbardziej jednorodne, często wybierana w praktyce, bo daje czyste, równe grupy

DeepDive™

HCA - Klastrowanie Hierarchiczne



DeepDive™

HCA – w służbie policji

Andrzej Porębski[1]

Analiza skupień zorganizowanych grup przestępczych jako przykład zastosowania metod statystycznych w kryminologii



DeepDive™

Gaussian Mixture Models

Algorytm, w którym każdy klaster modelujemy jako rozkład Gaussa
i dostajemy prawdopodobieństwo przynależności
do poszczególnych komponentów.

K-means:
Punkt A należy do klastra 2.

GMM:
Punkt A należy do
w 70% do klastra 1,
w 29% do klastra 2,
w 1% do klastra 3.

DeepDive™

Spectral clustering

Algorytm, w którym tworzymy graf podobieństwa między punktami.
Punkty to węzły, podobieństwa to krawędzie.
Wykorzystujemy strukturę grafu do znalezienia grup.



dobrze radzi sobie z nieliniową strukturą

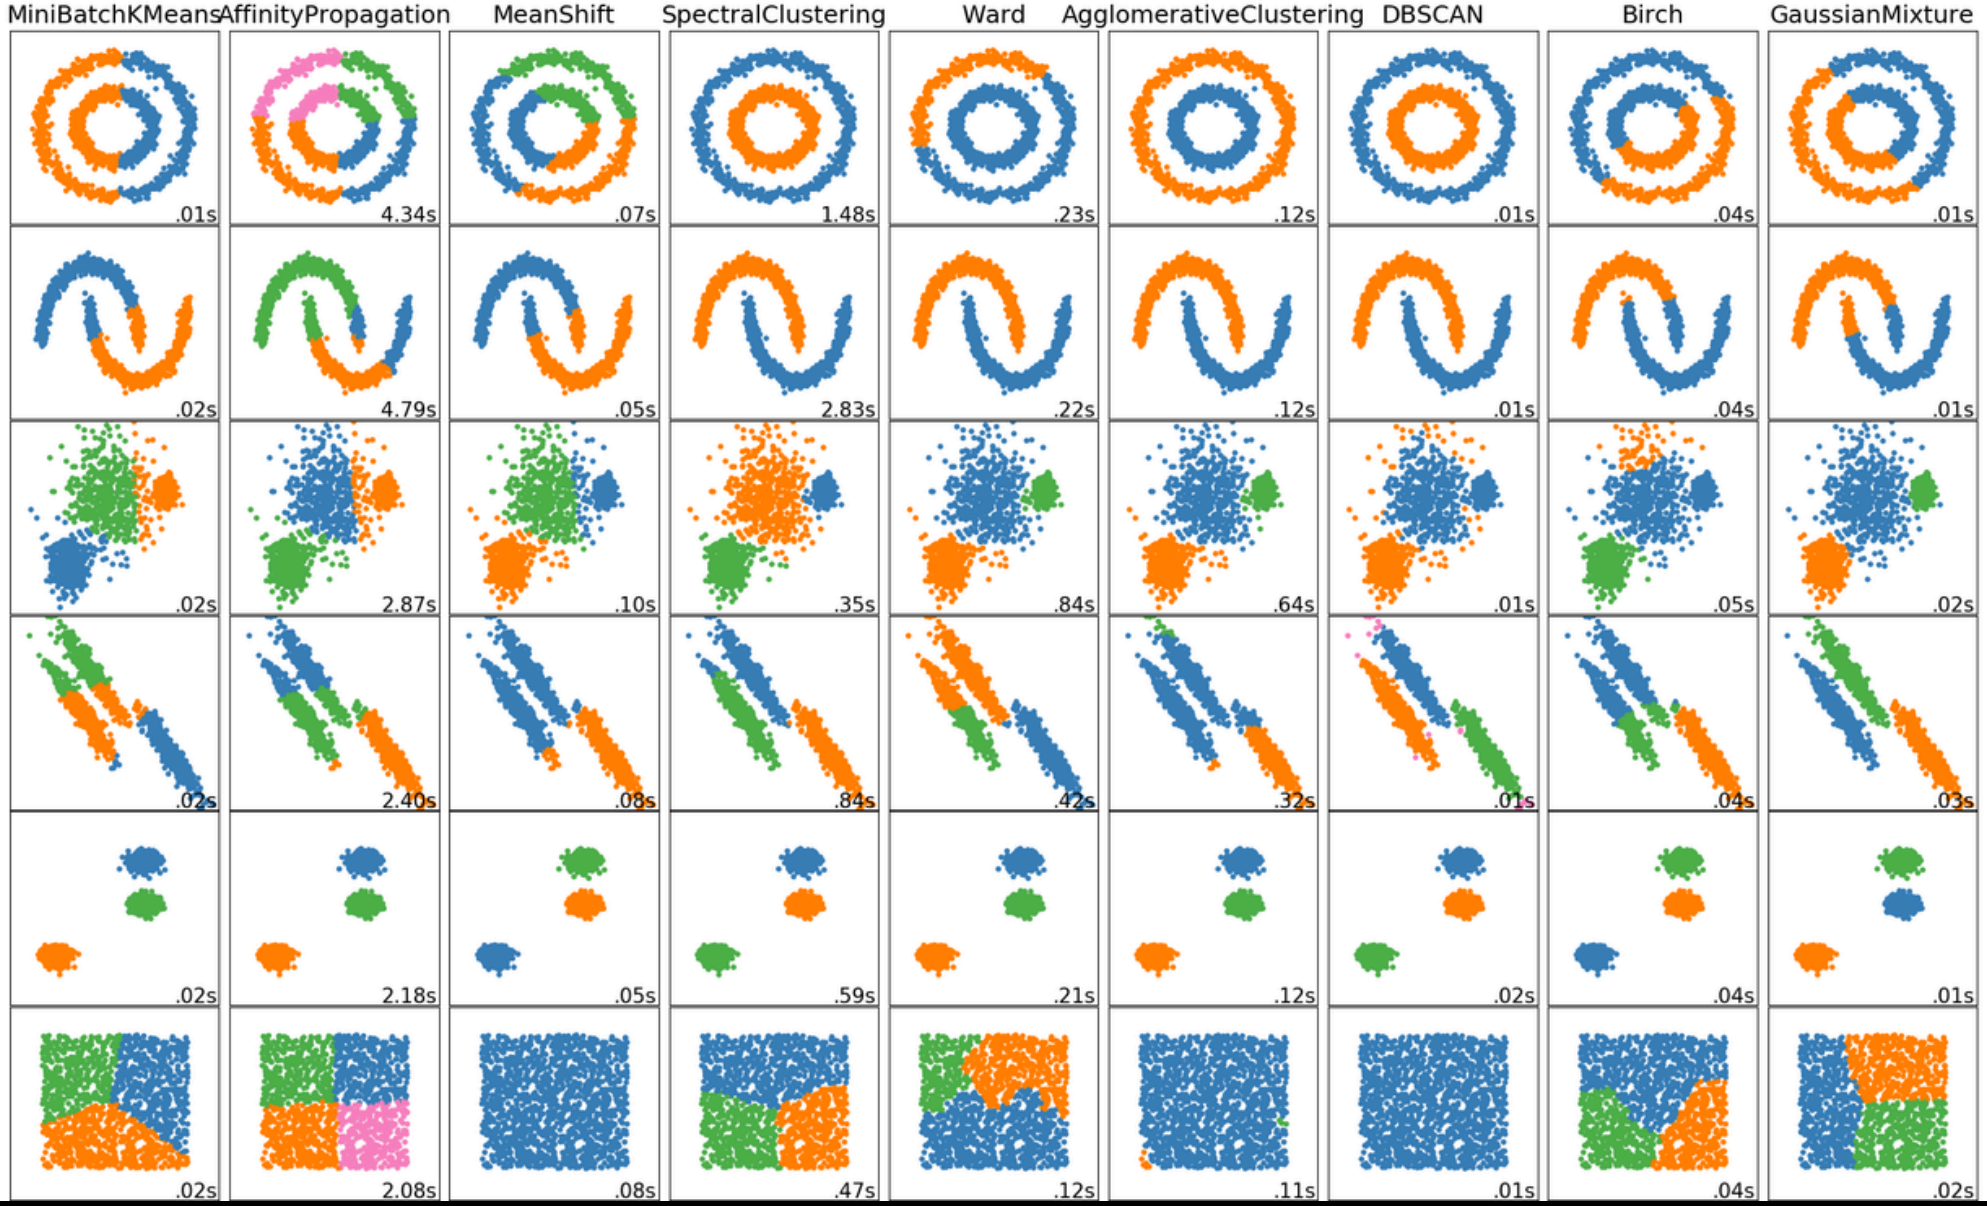
może znaleźć klastry o dziwnych kształtach



większy koszt obliczeniowy

słabsza skalowalność do ogromnych datasetów

DeepDive™


MiniBatchKMeans
AffinityPropagation
MeanShift
SpectralClustering
Ward
AgglomerativeClustering
DBSCAN
Birch
GaussianMixture
.01s 4.34s .07s 1.48s .23s .12s .01s .04s .01s
.02s 4.79s .05s 2.83s .22s .12s .01s .04s .01s
.02s 2.87s .10s .35s .84s .64s .01s .05s .02s
.02s 2.40s .08s .84s .42s .32s .01s .04s .03s
.02s 2.18s .05s .59s .21s .12s .02s .04s .01s
.02s 2.08s .08s .47s .12s .11s .01s .04s .02s

DeepDive™


DeepDive™